MATA KULIAH • MACHINE LEARNING

Workflow ML, CRISP-DM, dan Bias–Variance

Pertemuan 2

Dari tujuan masalah hingga model yang mampu bekerja pada data baru



Skor training 99% belum tentu berarti model berhasil

Bayangkan seorang mahasiswa menghafal seluruh jawaban latihan.

Di ruang latihan

Skor training = 99%
Semua contoh yang pernah dilihat dijawab hampir sempurna.



Saat menghadapi soal baru

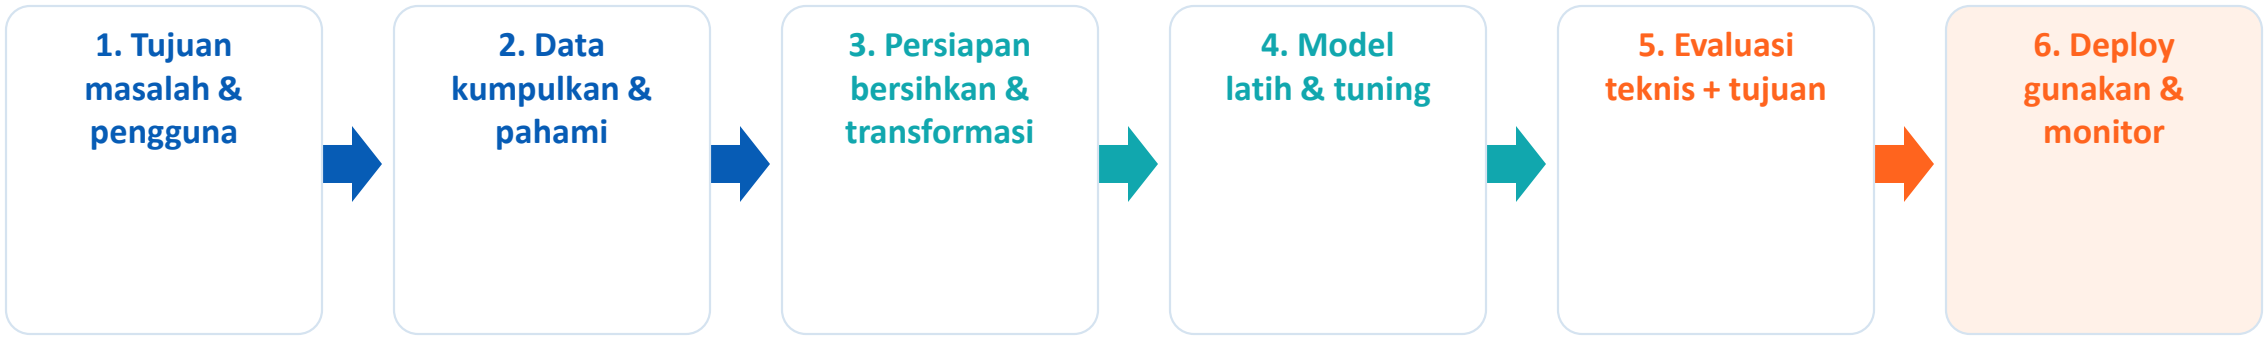
Skor test = 68%
Model gagal karena menghafal detail, bukan memahami pola.

Bagaimana membangun dan mengevaluasi model secara jujur?

Setelah pertemuan ini, Anda mampu…

01	**Menjelaskan enam fase CRISP-DM**	sebagai siklus kerja proyek ML, bukan urutan sekali jalan
02	**Membedakan train, validation, dan test**	berdasarkan fungsi dan waktu penggunaannya
03	**Menghitung pembagian data terstratifikasi**	agar proporsi kelas tetap terjaga
04	**Mendiagnosis bias dan variance**	melalui gap skor dan pola learning curve

Workflow ML menghubungkan masalah, model, dan keputusan



Model bukan tujuan akhir—model adalah bagian dari sistem pengambilan keputusan.

Tanpa workflow, ML dapat menjawab masalah yang salah

Tujuan kabur

Model akurat, tetapi tidak menjawab kebutuhan pengguna.

Contoh: memprediksi churn tanpa menentukan horizon waktu.

Evaluasi bocor

Informasi test ikut digunakan saat preprocessing atau tuning.

Akibat: skor terlihat terlalu optimistis.

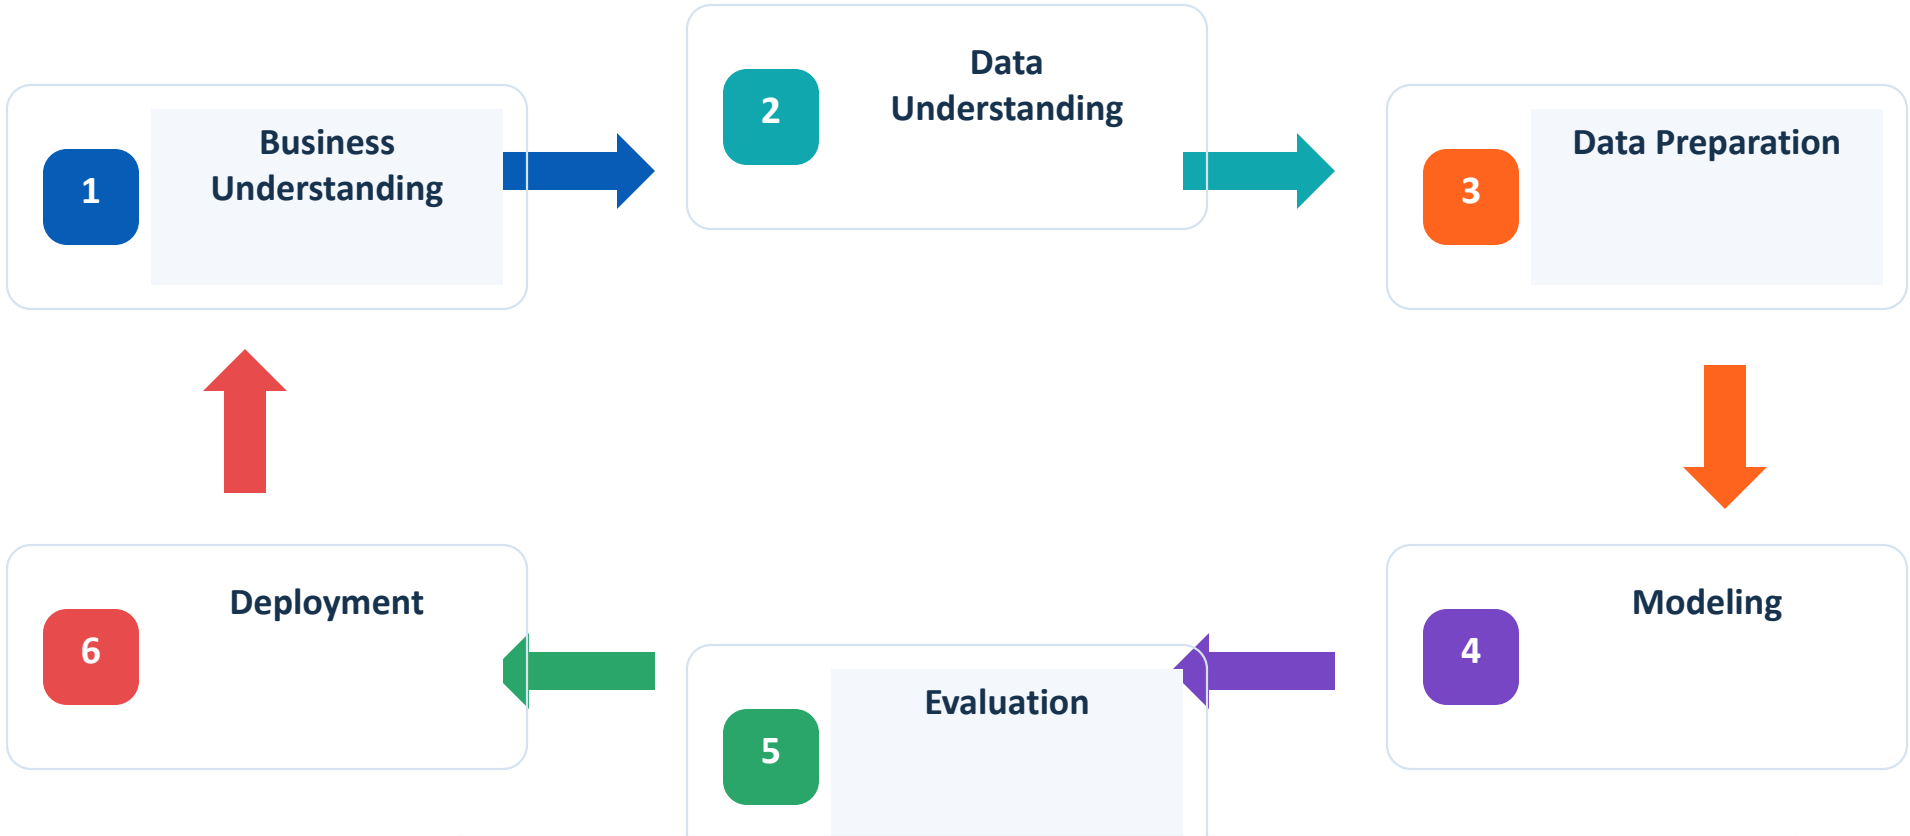
Model berhenti di notebook

Tidak ada integrasi, pemantauan, atau tindakan setelah prediksi.

Nilai praktis = nol.

CRISP-DM memberi struktur yang dapat diulang dan dikoreksi.

CRISP-DM menjaga proyek ML tetap terarah dan iteratif



Hasil evaluasi dapat mengirim tim kembali ke data, tujuan, atau persiapan.

Business Understanding mengubah kebutuhan menjadi target terukur

Kebutuhan awal

"Kami ingin mengurangi pelanggan yang berhenti berlangganan."

Masih terlalu umum: siapa, kapan, dan keberhasilannya bagaimana?

Pertanyaan ML

"Prediksi probabilitas pelanggan berhenti dalam 30 hari."

Target: churn / tidak churn
Metrik: recall kelas churn + dampak retensi

Mulai dari keputusan yang akan dibuat—bukan dari algoritma yang ingin dicoba.

Data Understanding menguji apakah data layak digunakan

Distribusi

- Berapa jumlah sampel?
- Bagaimana proporsi kelas?
- Apakah fitur miring atau memiliki outlier?

Kualitas

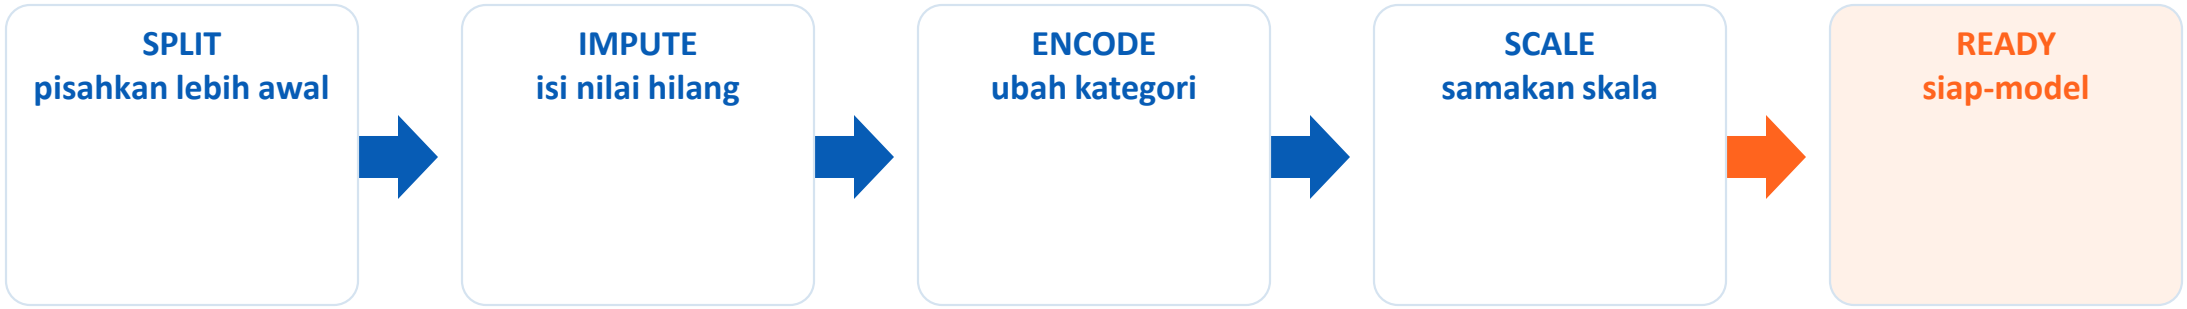
- Missing value
- Duplikasi
- Nilai tidak logis
- Label yang meragukan

Konteks

- Unit satu baris data
- Waktu pengukuran
- Sumber data
- Risiko leakage

EDA bukan sekadar membuat grafik; EDA menguji apakah data layak menjawab masalah.

Data Preparation harus mencegah kebocoran data



ATURAN AMAN

Imputer, encoder, dan scaler di-fit hanya pada TRAIN; validation/test hanya ditransformasi.

Modeling membandingkan pilihan, bukan mencari algoritma ajaib

1. Baseline

Bangun model sederhana sebagai titik pembanding.

Contoh: majority class atau pohon dangkal.

2. Kandidat

Pilih model sesuai tipe target, ukuran data, dan kebutuhan interpretasi.

3. Tuning

Atur hyperparameter memakai validation/CV—bukan test set.

Kompleksitas model harus dibenarkan oleh peningkatan generalisasi.

Evaluation harus menjawab dua pertanyaan sekaligus

Apakah model bekerja secara teknis?

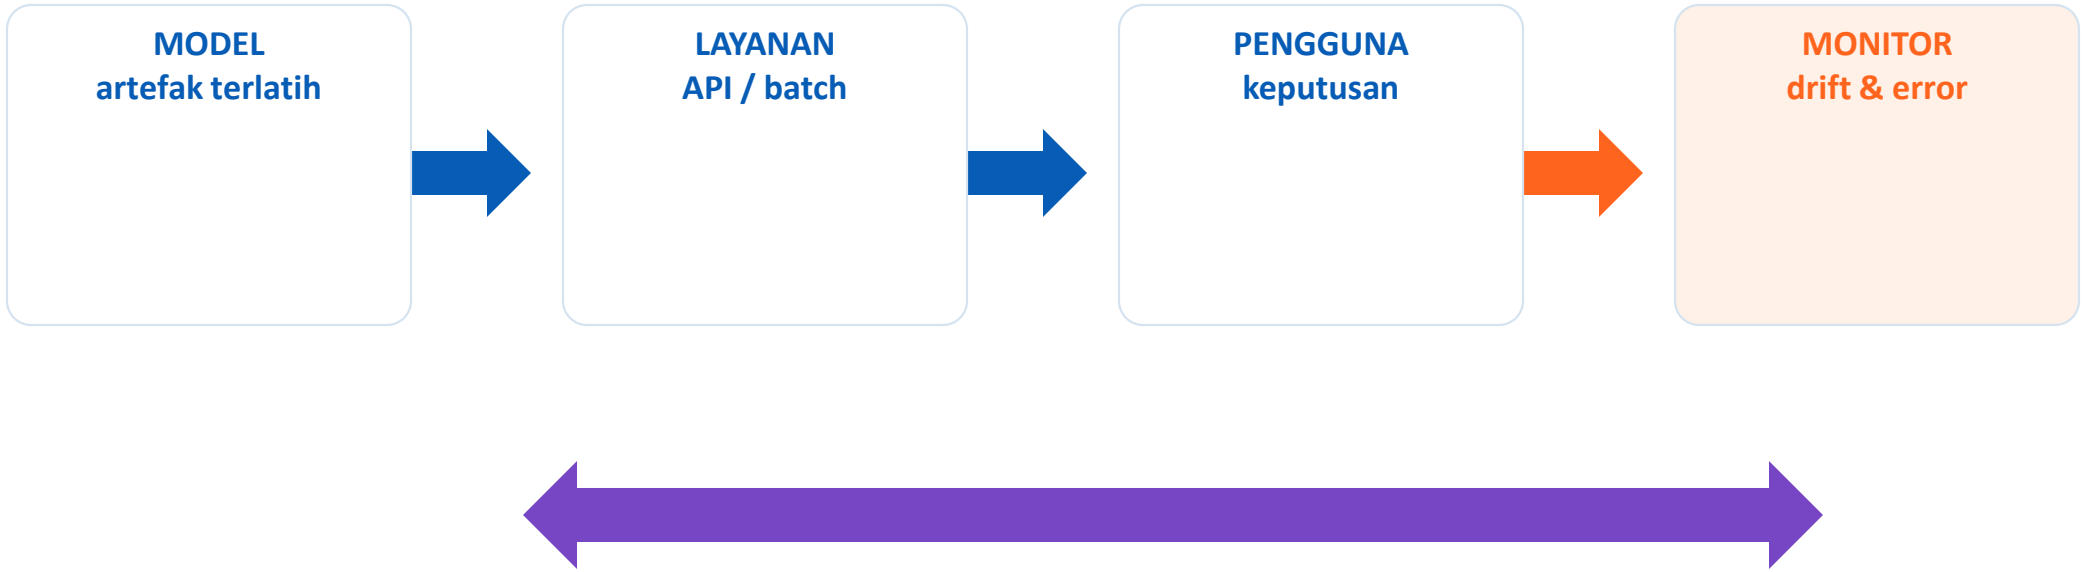
- Skor pada data yang belum dilihat
- Performa kelas minoritas
- Stabilitas antar-fold
- Gap train–validation
- Kalibrasi dan jenis kesalahan

Apakah model berguna untuk tujuan awal?

- Metrik sesuai biaya kesalahan
- Prediksi tersedia tepat waktu
- Dapat dipahami pengguna
- Risiko dan batas penggunaan diterima

Model dapat lulus secara teknis tetapi gagal memenuhi kebutuhan pengguna.

Deployment mengubah prediksi menjadi tindakan dan umpan balik



Monitoring memberi sinyal kapan data, target, atau model perlu diperbarui.

Temuan baru dapat mengirim proyek kembali ke fase sebelumnya

Evaluasi: recall churn rendah	→ **Kembali ke DATA**	periksa label dan representasi pelanggan churn
Prediksi terlambat digunakan	→ **Kembali ke TUJUAN**	ubah horizon prediksi dan alur keputusan
Drift setelah deployment	→ **Kembali ke MODEL**	latih ulang dan tinjau fitur yang berubah

Iterasi bukan kegagalan proses; iterasi adalah cara proses belajar.

Train, validation, dan test memiliki pekerjaan yang berbeda

TRAIN

Belajar parameter model
Dipakai berulang selama fit

VALIDATION

Memilih model dan hyperparameter
Dipakai selama tuning

TEST

Ujian akhir—hanya sekali



Proporsi split diterjemahkan langsung menjadi jumlah data

$n_{train} = p_{train} \times N$ • $n_{val} = p_{val} \times N$ • $n_{test} = p_{test} \times N$

Contoh: N = 1.000 data, pembagian 70% : 10% : 20%



0,70 × 1.000 = 700

0,10 × 1.000 = 100

0,20 × 1.000 = 200

Pastikan p_train + p_val + p_test = 1.

Stratified sampling menjaga komposisi kelas di setiap subset

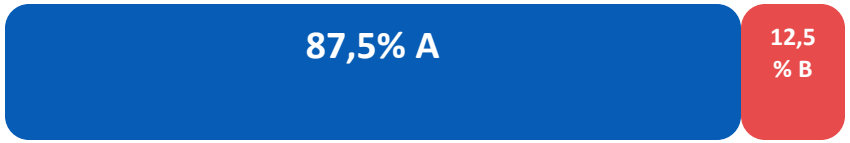
Dataset awal



TRAIN — STRATIFIED



TEST — RANDOM SPLIT



Proporsi dapat menyimpang

TEST — STRATIFIED



Proporsi tetap konsisten

Stratifikasi penting ketika kelas tidak seimbang.

Contoh hitung: 1.000 data dengan kelas A:B = 800:200

Rumus per kelas: $n_{k,subset} = p_subset \times n_k$

DATASET AWAL

Kelas A = 800
Kelas B = 200
Total = 1.000

TRAIN 80%

A: 0,8 × 800 = 640
B: 0,8 × 200 = 160
Total train = 800

TEST 20%

A: 0,2 × 800 = 160
B: 0,2 × 200 = 40
Total test = 200

Train dan test tetap memiliki rasio A:B = 80%:20%.

Data leakage membuat evaluasi tampak terlalu baik

ALUR AMAN

1. Split data
2. Fit imputer/scaler pada train
3. Transform validation/test
4. Tuning dengan validation/CV
5. Test hanya di akhir

✓ GENERALISASI DIUJI

ALUR BOCOR

1. Hitung mean/scaling dari semua data
2. Pilih fitur memakai test
3. Ulangi tuning berdasarkan skor test

Skor test tidak lagi independen.

✕ SKOR TERLALU OPTIMISTIS

Kesalahan prediksi dapat dipahami melalui bias dan variance

$$E[(Y - \hat{f}(X))^2] \approx \text{Bias}^2 + \text{Variance} + \sigma^2$$

BIAS²

Kesalahan sistematis karena model terlalu sederhana atau asumsi terlalu kuat.

Bias tinggi → underfitting.

VARIANCE

Model terlalu sensitif terhadap perubahan kecil pada data latih.

Variance tinggi → overfitting.

σ^2: NOISE

Variasi bawaan data atau pengukuran yang tidak dapat dihilangkan sepenuhnya.

Underfitting dan overfitting sama-sama gagal pada data baru



UNDERFITTING

bias tinggi • variance rendah

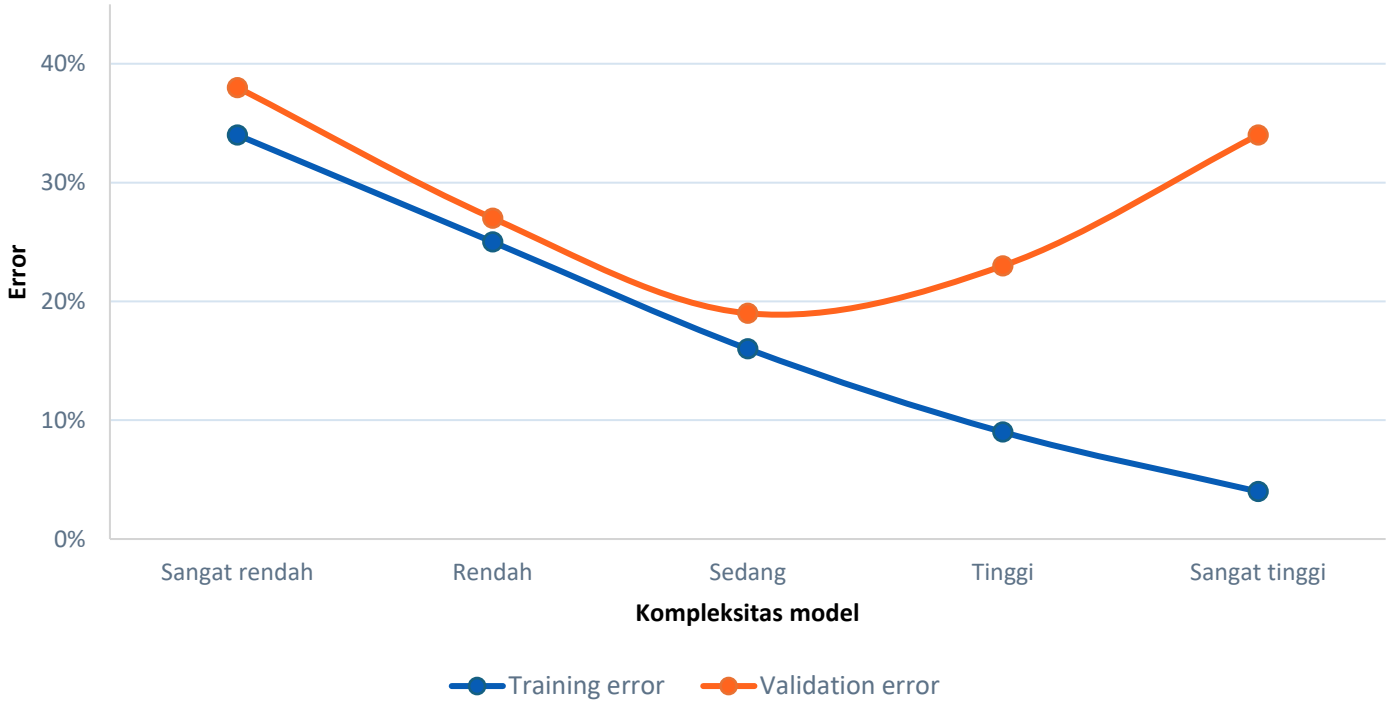
GOOD FIT

bias dan variance seimbang

OVERFITTING

bias rendah • variance tinggi

Kompleksitas yang tepat meminimalkan error validasi



BIAS TINGGI

Kiri: model terlalu sederhana. Train dan validation sama-sama buruk.

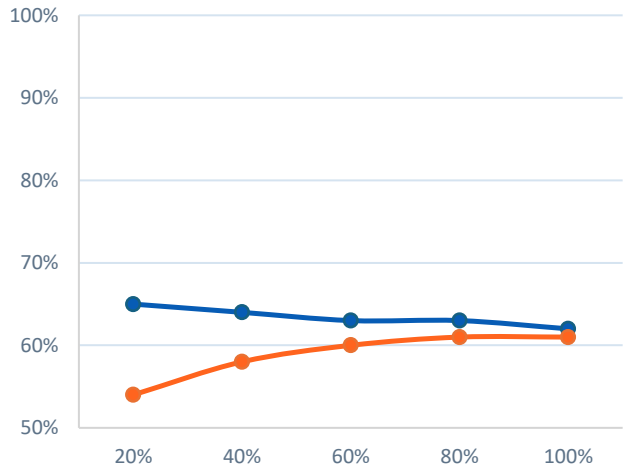
VARIANCE TINGGI

Kanan: error train terus turun, tetapi error validation meningkat.

SWEET SPOT = ERROR VALIDASI TERENDAH

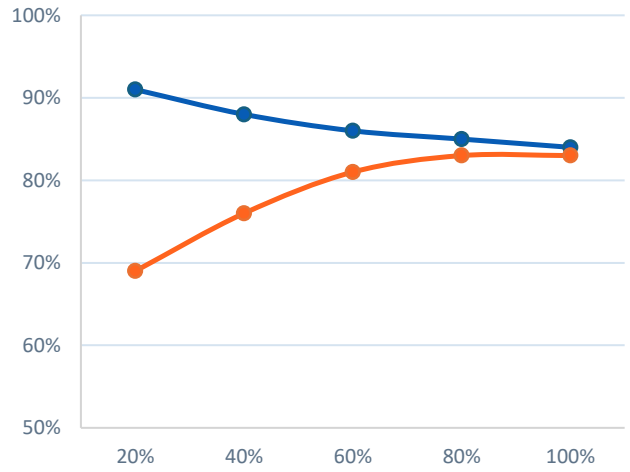
Learning curve memperlihatkan dampak penambahan data

UNDERFITTING



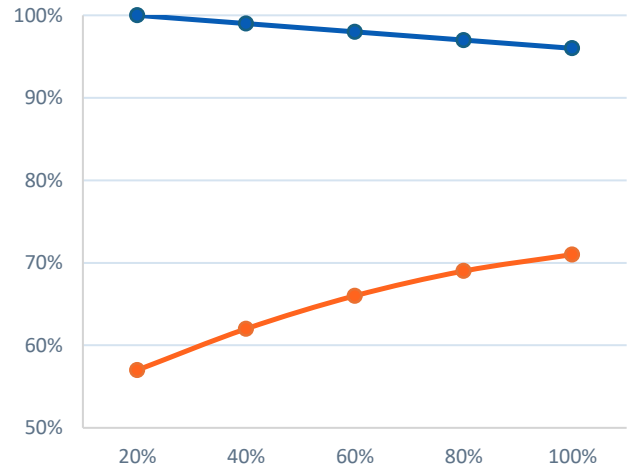
Keduanya rendah & dekat

GOOD FIT



Keduanya tinggi & dekat

OVERFITTING



Train tinggi, gap besar

Sumbu-x = jumlah data latih • Sumbu-y = skor performa

Contoh hitung membantu mengubah gejala menjadi diagnosis

A. DEKOMPOSISI ERROR

Diketahui (contoh hipotetik):
Bias = 0,15
Variance = 0,04
Noise = 0,02

Total error ≈ $0{,}15^2$ + 0,04 + 0,02
= 0,0225 + 0,04 + 0,02
= 0,0825

B. GENERALIZATION GAP

Skor train = 0,95
Skor validation = 0,78

Gap = skor_train − skor_validation
= 0,95 − 0,78
= 0,17 atau 17 poin persentase

Diagnosis: indikasi variance tinggi.

Angka tidak memiliki ambang universal; bandingkan dengan baseline, variasi fold, dan konteks masalah.

Praktikum: bandingkan learning curve tiga tingkat kompleksitas

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from sklearn.datasets import make_classification
from sklearn.model_selection import train_test_split,
learning_curve
from sklearn.tree import DecisionTreeClassifier

# Dataset sintetis untuk simulasi (dapat diganti dataset ny
ata,
mis. UCI/Kaggle)
X,y = make_classification(n_samples=1000,n_features=10,
n_informative=6,weights=[0.8,0.2],random_state=42)
print("Distribusi kelas:", np.bincount(y))
```

1. Buat dataset
2. Split + stratify
3. Latih depth 1, 4, ∞
4. Plot learning curve
5. **Tulis diagnosis**

Output: grafik + diagnosis tiga model.

Kesimpulan

1. CRISP-DM bersifat siklis: temuan baru boleh mengubah langkah sebelumnya.
2. Train belajar, validation memilih, test memberi evaluasi akhir.
3. Stratifikasi menjaga proporsi kelas dan membuat evaluasi lebih stabil.
4. Learning curve membantu membedakan bias tinggi dan variance tinggi.

Jika gap train–validation besar, tindakan apa yang Anda pilih dan mengapa?