MATA KULIAH • MACHINE LEARNING

Data Preparation Lanjutan

Missing Values • Outlier • Imbalanced Data

Pertemuan 3

Mengubah data bermasalah menjadi masukan model yang dapat dipercaya



Program Studi Teknik Informatika • FTIK

Akurasi 95% dapat menyembunyikan kegagalan total

Kasus deteksi fraud: 1.000 transaksi

DATA SEBENARNYA

950 transaksi normal
50 transaksi fraud

MODEL ‘CERDIK’ YANG SALAH

Memprediksi semua transaksi sebagai normal.

Akurasi = 950 / 1.000 = 95%

Pertanyaan: apakah data dan metrik kita membuat model tampak lebih baik daripada kenyataannya?

Setelah pertemuan ini, Anda mampu…

01	**Mendiagnosis missing values**	dan memilih strategi imputasi yang sesuai
02	**Mendeteksi serta menilai outlier**	sebelum memutuskan menghapus atau mempertahankannya
03	**Menangani imbalanced data**	dengan SMOTE, undersampling, atau class weight
04	**Membangun alur preprocessing aman**	yang hanya belajar dari data train

Tiga masalah data membutuhkan tiga jenis keputusan

MISSING VALUES

Ada informasi yang tidak tercatat.

Pertanyaan: hilangnya acak atau membawa pola tertentu?

OUTLIER

Nilai jauh dari mayoritas.

Pertanyaan: kesalahan data atau kejadian langka yang sah?

IMBALANCED DATA

Satu kelas jauh lebih sedikit.

Pertanyaan: apakah model mengabaikan kelas penting?

Tidak ada satu teknik yang selalu benar—keputusan harus mengikuti pola data dan konteks domain.

Split lebih awal menjaga preprocessing tetap jujur



ATURAN AMAN

Mean, median, tetangga KNN, dan sampel sintetis tidak boleh memperoleh informasi dari test set.

Missing values tidak selalu hilang secara acak

MCAR	**Hilang tidak terkait fitur maupun nilai yang hilang**	Contoh: formulir rusak secara acak
MAR	**Hilang terkait fitur lain yang teramati**	Contoh: pendapatan lebih sering kosong pada kelompok usia tertentu
MNAR	**Hilang terkait nilai yang justru tidak tercatat**	Contoh: pendapatan tinggi enggan dilaporkan

Pola missing memengaruhi apakah imputasi sederhana masih dapat dipercaya.

Menghapus semua baris kosong dapat mengubah populasi data

SEBELUM DROPNA

1.000 responden
200 nilai pendapatan kosong

Nilai kosong lebih sering muncul pada kelompok tertentu.

SETELAH DROPNA

Tersisa 800 responden

Kelompok yang sering tidak menjawab menjadi kurang terwakili.

Missing value bukan hanya masalah teknis; ia dapat menimbulkan bias representasi.

Strategi imputasi dipilih dari proporsi dan pola missing

DROP

Cepat dan sederhana

Jika missing sangat kecil dan relatif acak

MEAN / MEDIAN

Murah dan mudah

Mean untuk simetris; median untuk data skewed

KNN IMPUTER

Memakai kemiripan

Ketika fitur lain memberi konteks yang kuat

ITERATIVE

Memodelkan hubungan

Ketika pola antarfitur kompleks

Validasi pilihan imputasi melalui performa model dan kewajaran nilai hasil imputasi.

Mean dan median dapat memberi hasil imputasi berbeda

Data pendapatan (juta): 4, 5, 5, 6, 30, ?

IMPUTASI MEAN

Mean = (4 + 5 + 5 + 6 + 30) / 5
= 50 / 5 = 10

Nilai kosong diisi 10.

IMPUTASI MEDIAN

Urutkan: 4, 5, 5, 6, 30
Median = nilai tengah = 5

Nilai kosong diisi 5.

Karena data miring oleh nilai 30, median lebih tahan terhadap nilai ekstrem.

KNN Imputer mengisi nilai dari data yang paling mirip

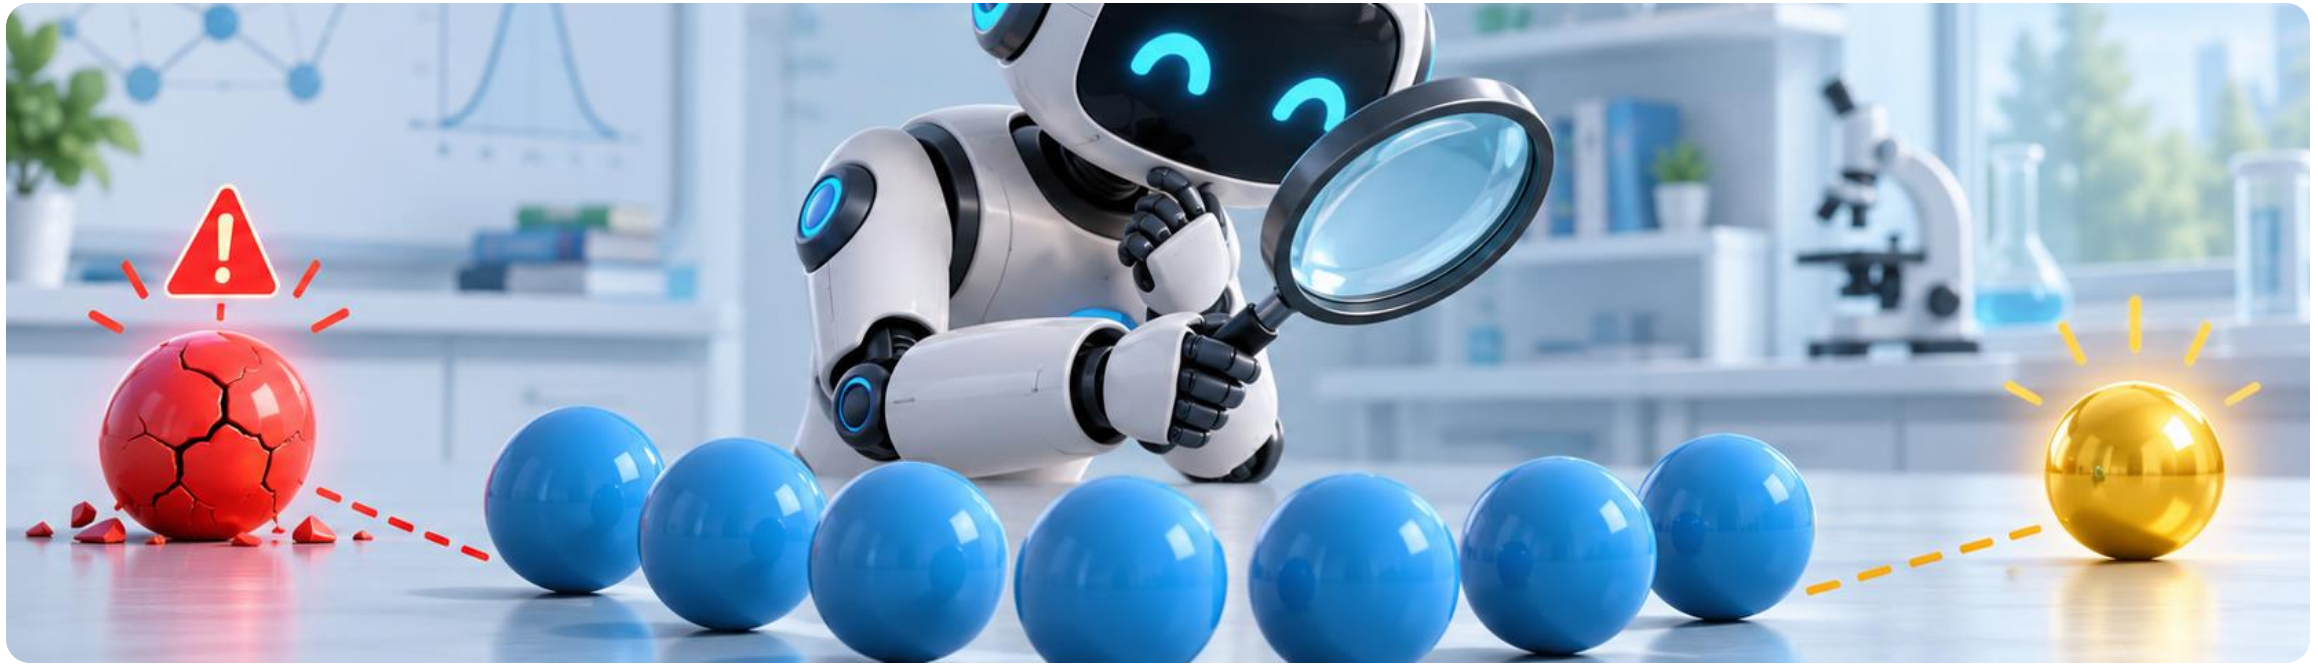
Intuisi

1. Ukur kemiripan dari fitur yang tersedia.
2. Pilih k tetangga terdekat.
3. Isi nilai hilang dari rata-rata tetangga.

Contoh: k = 3, nilai tetangga = 24, 26, 28
Imputasi = (24 + 26 + 28) / 3 = 26



Outlier harus diperiksa, bukan otomatis dihapus



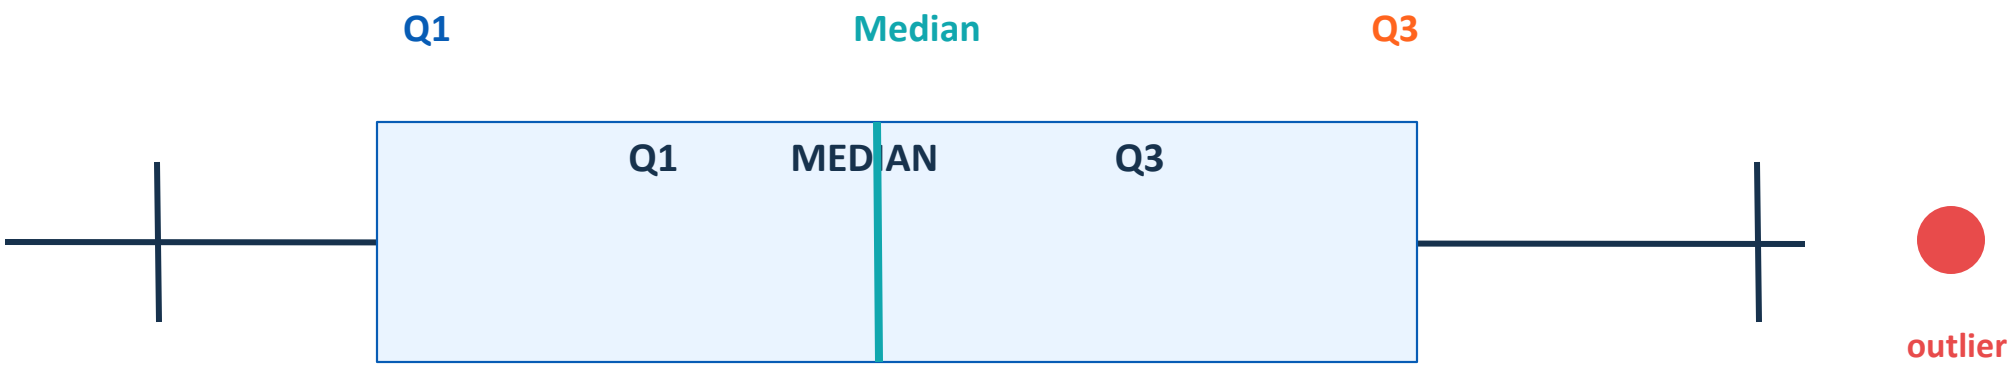
KESALAHAN DATA

Salah input atau unit → koreksi/hapus.

FENOMENA LANGKA

Valid dan penting → pertahankan.

Boxplot merangkum pusat, sebaran, dan titik ekstrem



$$IQR = Q3 - Q1$$

Kotak memuat 50% data tengah; titik di luar pagar IQR ditandai sebagai kandidat outlier.

Contoh IQR menunjukkan mengapa nilai 95 terdeteksi

Data usia: 22, 24, 25, 27, 29, 30, 31, 95

1. Q1 = (24 + 25)/2 = 24,5 dan Q3 = (30 + 31)/2 = 30,5
2. IQR = Q3 − Q1 = 30,5 − 24,5 = 6
3. Batas atas = Q3 + 1,5 × IQR
4. **= 30,5 + 1,5 × 6 = 39,5**

95 > 39,5 → 95 adalah kandidat outlier menurut aturan IQR

Z-score mengukur jarak nilai dari rata-rata

$$z = (x - \mu) / \sigma$$

CONTOH

Rata-rata $\mu = 50$
Standar deviasi $\sigma = 10$
Nilai pengamatan $x = 85$

PERHITUNGAN

$z = (85 - 50) / 10$
$= 35 / 10$
$= 3,5$

Karena $|3,5| > 3$, nilai 85 ditandai sebagai kandidat outlier.

Perlakuan outlier mengikuti penyebab dan tujuan analisis

KOREKSI

Jika salah input atau salah unit

HAPUS

Jika jelas tidak valid dan tidak dapat diperbaiki

TRANSFORMASI

Log/capping untuk mengurangi pengaruh ekstrem

PERTAHANKAN

Jika sah dan penting bagi tujuan model

Dokumentasikan alasan tindakan; jangan menyesuaikan data hanya agar skor model naik.

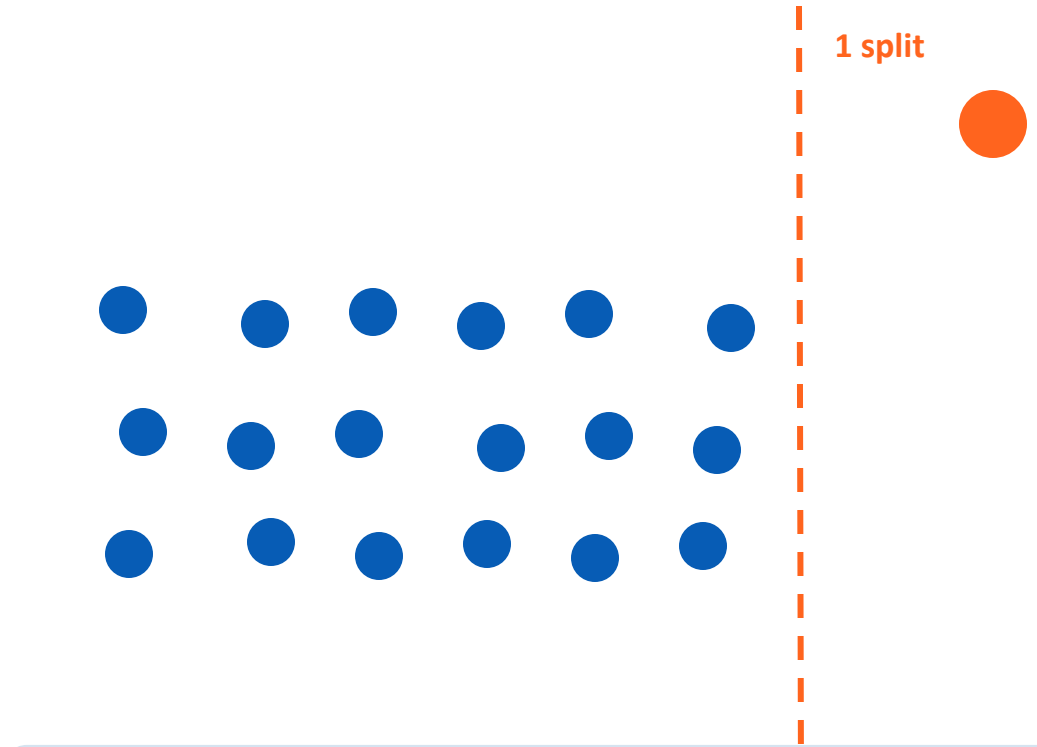
Isolation Forest mencari titik yang mudah dipisahkan

Titik normal

Berada di kelompok padat sehingga memerlukan banyak split acak untuk diisolasi.

Titik anomali

Berada jauh dari kelompok sehingga dapat diisolasi hanya dengan sedikit split.



Semakin pendek jalur isolasi, semakin besar skor anomalinya.

Kelas minoritas sedikit, tetapi sering paling penting



KELAS MAYORITAS

Mendominasi fungsi objektif dan akurasi.

KELAS MINORITAS

Jumlah kecil, tetapi biaya gagal mendeteksinya tinggi.

Masalahnya bukan sekadar rasio; masalahnya adalah model tidak belajar kelas yang dibutuhkan.

Model semua-normal memperoleh 95% akurasi dan 0% recall

	Prediksi: NORMAL	Prediksi: FRAUD
Aktual NORMAL	TN = 950	FP = 0
Aktual FRAUD	FN = 50	TP = 0

Accuracy = (950 + 0) / 1.000 = 95% • Recall fraud = 0 / (0 + 50) = 0%

Precision, recall, dan F1 menilai kelas yang ingin ditemukan

PRECISION

Dari semua prediksi positif, berapa yang benar?

Precision = TP / (TP + FP)

RECALL

Dari semua kasus positif, berapa yang ditemukan?

Recall = TP / (TP + FN)

F1-SCORE

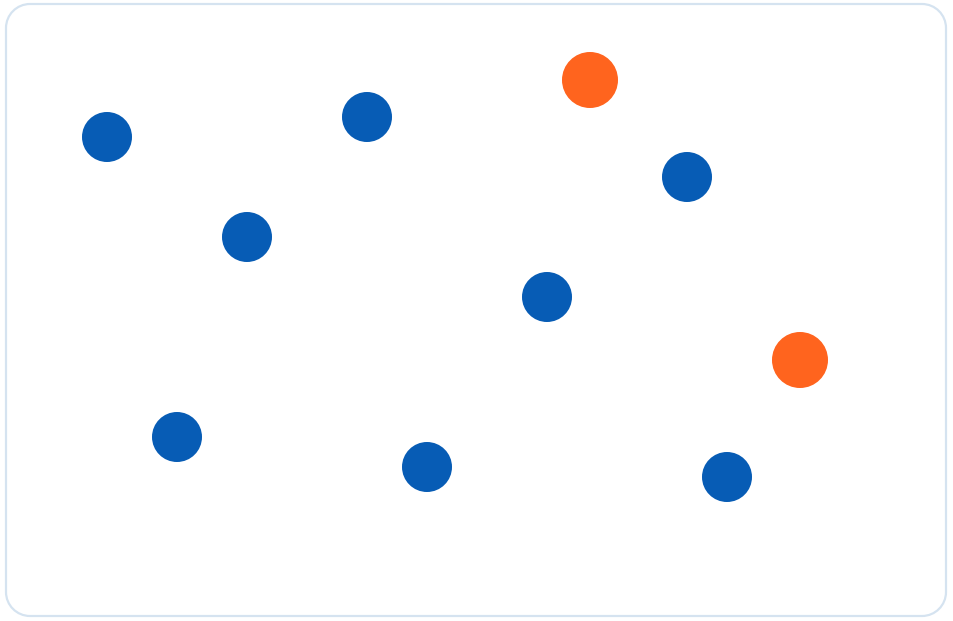
Keseimbangan precision dan recall.

F1 = 2PR / (P + R)

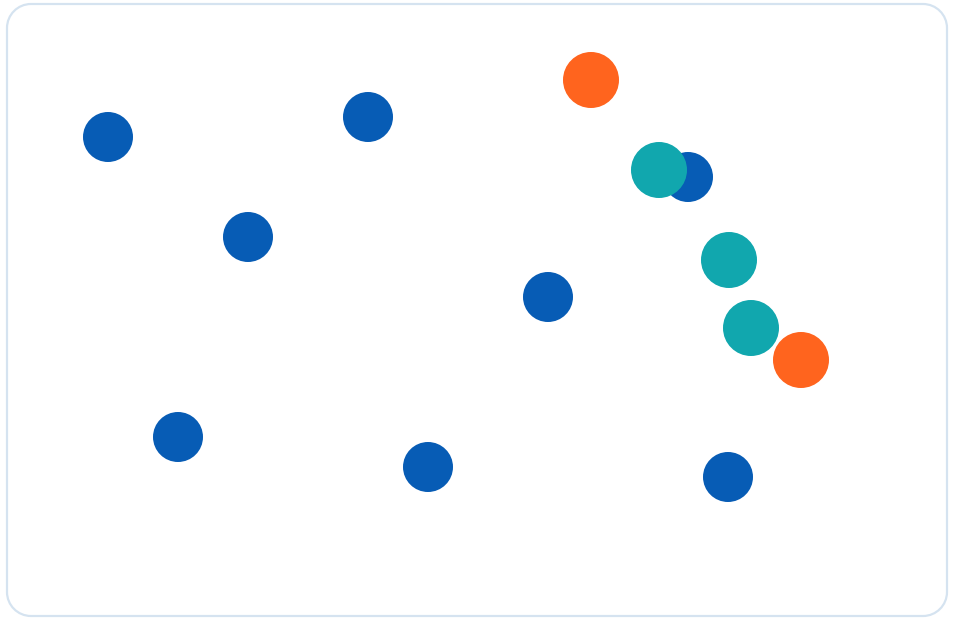
Untuk fraud atau penyakit, recall sering penting karena false negative memiliki biaya besar.

SMOTE membuat titik baru di antara tetangga minoritas

Sebelum SMOTE



Sesudah SMOTE



Sampel sintetis dibuat hanya dari kelas minoritas pada TRAIN set.

Contoh SMOTE: interpolasi menghasilkan satu sampel baru

$$x' = x_i + \lambda(x_j - x_i), \quad 0 \le \lambda \le 1$$

TITIK AWAL

$x_i = (2, 3)$

TETANGGA

$x_j = (6, 5)$

λ = 0,25

$x' = (2,3) + 0{,}25[(6,5) - (2,3)]$
$= (2,3) + (1,0,5)$
$= (3, 3{,}5)$

Titik baru berada di antara dua sampel minoritas—bukan hasil salinan.

SMOTE, undersampling, dan class weight mengubah hal berbeda

SMOTE

Menambah sampel minoritas sintetis

+ variasi minoritas
− dapat membuat titik tidak realistis

UNDERSAMPLING

Mengurangi sampel mayoritas

+ cepat
− membuang informasi

CLASS WEIGHT

Memperbesar penalti kelas minoritas

+ data tetap utuh
− tidak semua algoritma mendukung

Bandingkan metode pada validation set; tidak ada metode yang selalu menang.

Class weight memberi penalti lebih besar pada kelas langka

$$w_k = N / (K \times n_k)$$

Contoh: N = 1.000, K = 2, n_normal = 950, n_fraud = 50

NORMAL

w_normal = 1.000 / (2 × 950)
= 0,526

FRAUD

w_fraud = 1.000 / (2 × 50)
= 10

Satu kesalahan pada fraud mendapat penalti sekitar 19× kesalahan pada normal.

Praktikum: bandingkan baseline, SMOTE, dan class weight

```
from sklearn.model_selection import train_test_split
from sklearn.impute import KNNImputer
from sklearn.linear_model import LogisticRegression
from imblearn.over_sampling import SMOTE

X_tr, X_te, y_tr, y_te = train_test_split(
    X, y, test_size=0.2, stratify=y, random_state=42)

imputer = KNNImputer(n_neighbors=5)
X_tr = imputer.fit_transform(X_tr)
X_te = imputer.transform(X_te)

X_sm, y_sm = SMOTE(random_state=42).fit_resample(X_tr, y_tr)
model = LogisticRegression(max_iter=1000).fit(X_sm, y_sm)
```

1. Split + stratify
2. Fit KNN imputer pada train
3. SMOTE hanya pada train
4. Bandingkan F1 dan recall
5. **Tulis keputusan**

Output: tabel metrik + alasan memilih teknik.

Kesimpulan

1. Kenali pola missing sebelum memilih imputasi.
2. Outlier adalah sinyal untuk diperiksa, bukan otomatis dibuang.
3. Pada kelas tidak seimbang, akurasi saja dapat menyesatkan.
4. SMOTE dan undersampling hanya diterapkan pada train set.
5. Pilih teknik dari bukti validasi dan konteks domain.

Jika akurasi naik tetapi recall kelas minoritas turun, apakah model membaik? Jelaskan.