MATA KULIAH • MACHINE LEARNING

Feature Engineering dan Pipeline

Konstruksi • Seleksi Fitur • ColumnTransformer

Pertemuan 4

Membuat representasi data yang informatif, konsisten, dan siap digunakan model



Program Studi Teknik Informatika • FTIK

Data yang sama dapat menghasilkan model yang berbeda

Prediksi harga rumah

FITUR MENTAH

luas = 120 m²
jumlah kamar = 4
tanggal bangun = 2005-06-10



FITUR BERMAKNA

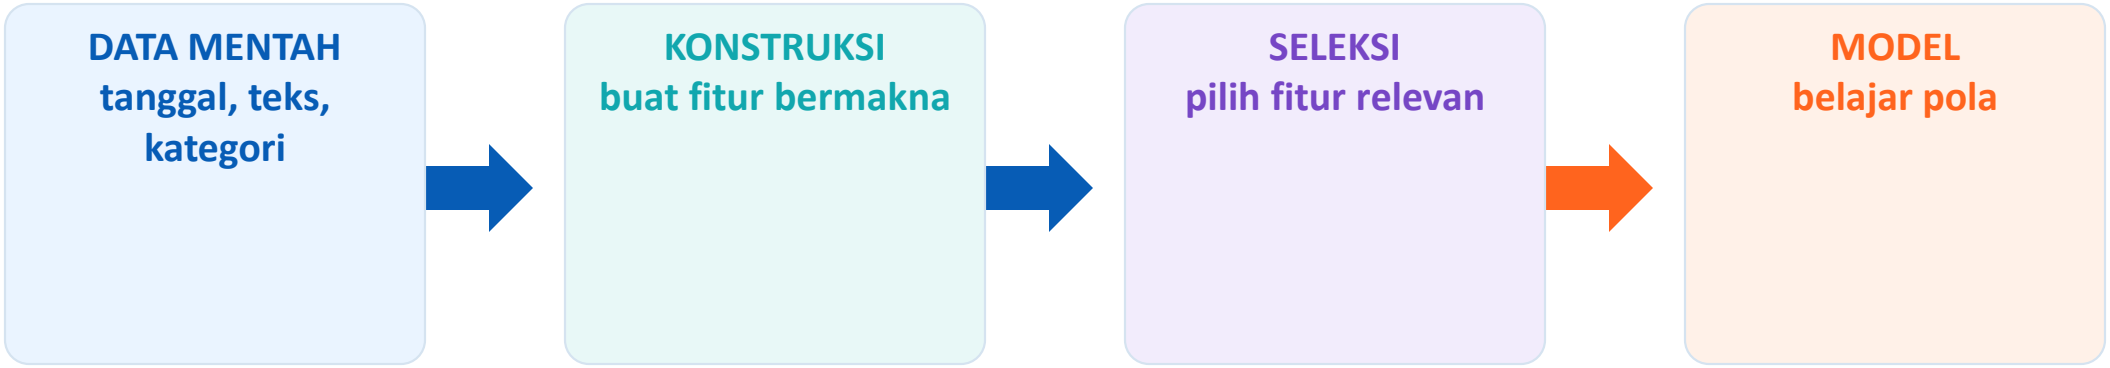
usia bangunan = 21 tahun
rasio kamar/luas = 0,033
musim transaksi = hujan

Model tidak melihat rumah; model melihat angka dan kategori yang kita rancang.

Setelah pertemuan ini, Anda mampu…

01	**Membangun fitur baru**	melalui polynomial, interaction, rasio, dan waktu
02	**Membandingkan metode seleksi fitur**	filter, wrapper, dan embedded
03	**Menghitung chi-square sederhana**	untuk fitur dan target kategorikal
04	**Menyusun Pipeline end-to-end**	untuk kolom numerik, kategorikal, dan ordinal

Feature engineering menjembatani data mentah dan model



Tujuannya bukan membuat fitur sebanyak mungkin, tetapi membuat informasi lebih mudah dipelajari.

Konstruksi menambah makna; seleksi mengurangi gangguan

FEATURE CONSTRUCTION

Menghasilkan fitur baru dari data yang tersedia.

Contoh:
- luas²
- luas × skor lokasi
- usia bangunan

FEATURE SELECTION

Memilih subset fitur yang paling berguna.

Tujuan:
- mengurangi noise
- mempercepat model
- meningkatkan interpretasi

Keduanya dapat digabungkan di dalam Pipeline yang sama.

Polynomial features membantu model menangkap pola melengkung

Model linear dengan fitur polynomial derajat 2

$$\hat{y} = \beta_0 + \beta_1 x + \beta_2 x^2$$

CONTOH x = 3

Fitur asli: [3]
Fitur polynomial: [3, 3^2] = [3, 9]

MAKNA

Model linear kini dapat memberi bobot berbeda untuk x dan x^2.

Derajat terlalu tinggi dapat menambah noise dan meningkatkan overfitting.

Interaction term menangkap efek gabungan antarfitur

$$x_interaksi = x_1 \times x_2$$

LUAS RUMAH

$x_1 = 120\ m^2$

SKOR LOKASI

$x_2 = 0{,}8$

INTERAKSI

$120 \times 0{,}8 = 96$

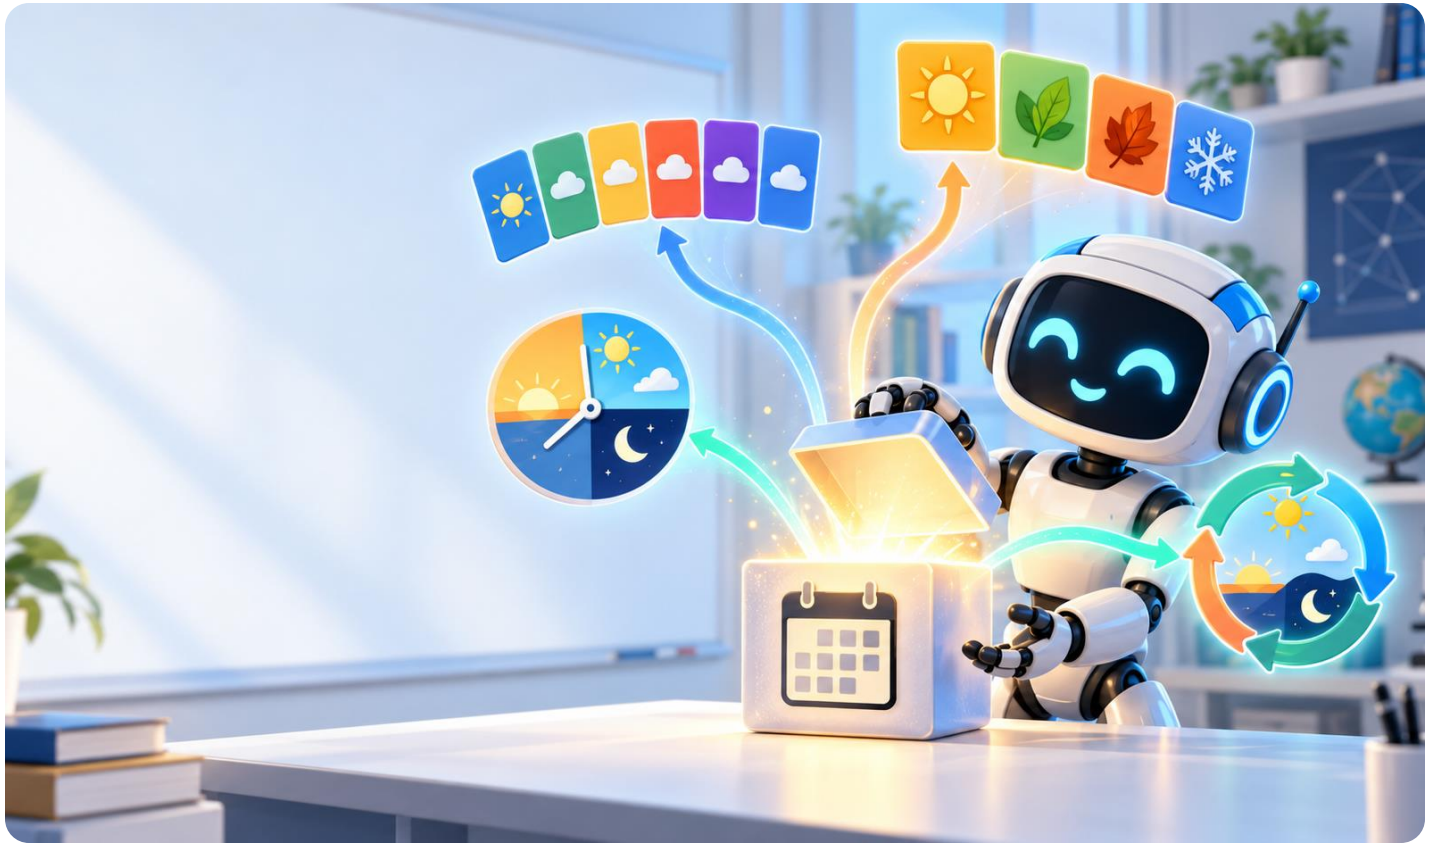
Pengaruh luas rumah dapat berbeda menurut kualitas lokasi; interaksi membuat efek gabungan terlihat.

Timestamp mentah perlu diubah menjadi pola waktu

Dari satu timestamp, kita dapat mengekstrak:

- hari dalam minggu
- bulan atau musim
- jam dan bagian hari
- akhir pekan
- siklus sin/cos

Contoh: 2026-09-07 08:00
→ Senin • September • pagi



Fitur yang memakai informasi masa depan menyebabkan leakage

FITUR AMAN

Prediksi churn pada 1 September

- transaksi sampai 31 Agustus
- lama berlangganan
- keluhan sebelumnya

✓ TERSEDIA SAAT PREDIKSI

FITUR BOCOR

Prediksi churn pada 1 September

- tanggal penutupan akun
- refund setelah berhenti
- status churn final

✕ BERASAL DARI MASA DEPAN

Lebih banyak fitur tidak selalu membuat model lebih baik

NOISE

Fitur acak menambah pola palsu dan variance.

REDUNDANSI

Dua fitur membawa informasi yang hampir sama.

BIAYA

Waktu latih, memori, dan kompleksitas interpretasi meningkat.

Feature selection mempertahankan sinyal sambil mengurangi gangguan dan biaya.

Tiga keluarga seleksi fitur memakai sumber koreksi berbeda

FILTER

Skor statistik data

Cepat; tidak bergantung model

WRAPPER

Skor model berulang

Menilai subset secara langsung

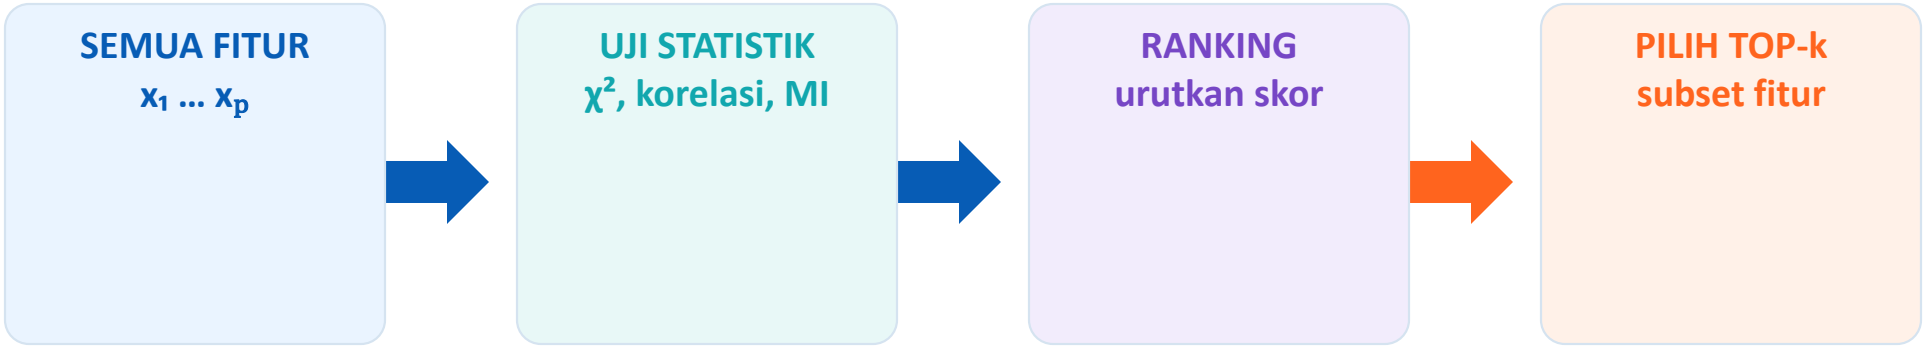
EMBEDDED

Proses training model

Seleksi terjadi saat model dilatih

Perbedaannya terletak pada siapa yang menilai kegunaan fitur.

Filter method memberi skor sebelum model dilatih



KELEBIHAN

Cepat dan murah; cocok untuk fitur sangat banyak.

KETERBATASAN

Tidak melihat interaksi fitur dengan model tertentu.

Korelasi tinggi dapat menandakan fitur yang redundan

Matriks korelasi contoh

	Luas	Kamar	Tanah	Usia
Luas	1	0,8	0,65	-0,2
Kamar	0,8	1	0,45	-0,1
Tanah	0,65	0,45	1	-0,15
Usia	-0,2	-0,1	-0,15	1

INTERPRETASI

corr(luas, kamar) = 0,80

Keduanya membawa informasi mirip. Menghapus salah satu dapat mengurangi redundansi—tetapi keputusan tetap divalidasi.

Korelasi tidak sama dengan sebab-akibat dan hanya menangkap hubungan tertentu.

Chi-square membandingkan frekuensi observasi dan harapan

$$\chi^2 = \Sigma (O_i - E_i)^2 / E_i$$

OBSERVED (O)

Frekuensi yang benar-benar terlihat pada tabel data.

EXPECTED (E)

Frekuensi yang diharapkan jika fitur dan target tidak berhubungan.

Semakin besar selisih O dan E, semakin kuat indikasi adanya hubungan.

Frekuensi harapan dihitung dari total baris dan kolom

$$E_{ij} = (\text{total baris } i \times \text{total kolom } j) / N$$

Tabel 100 pelanggan

Metode	Churn Ya	Churn Tidak	Total
Tunai	10	40	50
Kredit	20	30	50
Total	**30**	**70**	**100**

CONTOH E

E(Tunai, Ya)
= 50 × 30 / 100
= 15

Karena kedua total baris = 50, nilai E untuk Ya = 15 dan Tidak = 35.

Contoh chi-square menghasilkan nilai 4,76

$$\chi^2 = (10-15)^2/15 + (40-35)^2/35 + (20-15)^2/15 + (30-35)^2/35$$

Tunai–Ya

25/15 = 1,667

Tunai–Tidak

25/35 = 0,714

Kredit–Ya

25/15 = 1,667

Kredit–Tidak

25/35 = 0,714

$$\chi^2 = 1{,}667 + 0{,}714 + 1{,}667 + 0{,}714 = 4{,}762 \approx 4{,}76$$

df = 1; karena 4,76 > 3,84 (α = 0,05), ada indikasi hubungan metode pembayaran–churn.

RFE menghapus fitur terlemah secara bertahap



Kuat karena memakai performa model, tetapi biaya dapat mencapai $O(p)$ hingga $O(p^2)$ training.

Regularisasi L1 dapat membuat koefisien fitur menjadi nol

$$\text{Loss_L1} = \text{Loss_asli} + \lambda \Sigma |w_i|$$

CONTOH PENALTI

Loss_asli = 0,30
λ = 0,10
w = [2, −1, 0,5]

Penalti = 0,10(2 + 1 + 0,5) = 0,35

TOTAL LOSS

Loss_L1 = 0,30 + 0,35
= 0,65

Model terdorong mengecilkan koefisien yang tidak cukup berguna.

Jika $w_i = 0$, fitur i secara efektif tidak digunakan oleh model.

Pilih metode seleksi sesuai skala data dan model

FILTER

KELEBIHAN
Cepat, murah, model-agnostic

KETERBATASAN
Dapat melewatkan interaksi

WRAPPER

KELEBIHAN
Menilai performa subset aktual

KETERBATASAN
Mahal untuk p besar

EMBEDDED

KELEBIHAN
Efisien dan terintegrasi

KETERBATASAN
Bergantung asumsi model

Gunakan cross-validation untuk menilai apakah subset terpilih benar-benar meningkatkan generalisasi.

ColumnTransformer memberi perlakuan berbeda untuk tiap tipe kolom



NUMERIK
impute + scale

KATEGORIKAL
impute + one-hot

ORDINAL
encode sesuai urutan

Pipeline menyatukan preprocessing dan model tanpa mengintip test




```
pipeline.fit(X_train, y_train)
pipeline.predict(X_test)
```

Test hanya melewati transformasi yang sudah dipelajari dari train.

Studi kasus harga rumah memakai fitur campuran

NUMERIK	luas, jumlah kamar, rasio kamar/luas	→	median + StandardScaler
KATEGORIKAL	tipe properti, kota	→	modus + OneHotEncoder
ORDINAL	kondisi: buruk → sangat baik	→	OrdinalEncoder dengan urutan

Feature construction: usia_bangunan dan rasio_kamar_per_luas

Kode ColumnTransformer memisahkan tiga jalur fitur

```
num_pipe = Pipeline([
  ("imputer", SimpleImputer(strategy="median")),
  ("scaler", StandardScaler())
])

cat_pipe = Pipeline([
  ("imputer", SimpleImputer(strategy="most_frequent")),
  ("onehot", OneHotEncoder(handle_unknown="ignore"))
])

preprocessor = ColumnTransformer([
  ("num", num_pipe, fitur_numerik),
  ("cat", cat_pipe, fitur_kategorikal),
  ("ord", OrdinalEncoder(categories=urutan), fitur_ordinal)
])
```

NUMERIK

Median → scaling

KATEGORIKAL

Modus → one-hot

ORDINAL

Kategori → urutan angka

Praktikum: bangun Pipeline Titanic dan bandingkan fitur

```
X = titanic[["age", "fare", "sex", "embarked"]]
y = titanic["survived"]

preprocess = ColumnTransformer([
  ("num", num_pipe, ["age", "fare"]),
  ("cat", cat_pipe, ["sex", "embarked"])
])

pipe = Pipeline([
  ("prep", preprocess),
  ("model", LogisticRegression(max_iter=1000))
])

pipe.fit(X_train, y_train)
y_pred = pipe.predict(X_test)
```

1. Buat split terstratifikasi
2. Definisikan kolom
3. Bangun ColumnTransformer
4. Bandingkan semua vs fitur terpilih
5. **Laporkan akurasi dan F1**

Output: Pipeline + daftar fitur + tabel metrik.

Kesimpulan

1. Fitur adalah representasi masalah, bukan sekadar kolom data.
2. Konstruksi fitur menambah makna; seleksi mengurangi gangguan.
3. Chi-square menilai perbedaan frekuensi observasi dan harapan.
4. ColumnTransformer memproses tipe kolom melalui jalur berbeda.
5. Pipeline menjaga preprocessing konsisten dan bebas leakage.

Sebutkan satu fitur baru yang dapat dibuat dari timestamp transaksi dan mengapa fitur itu berguna.