MATA KULIAH MACHINE LEARNING

KNN dan Naive Bayes

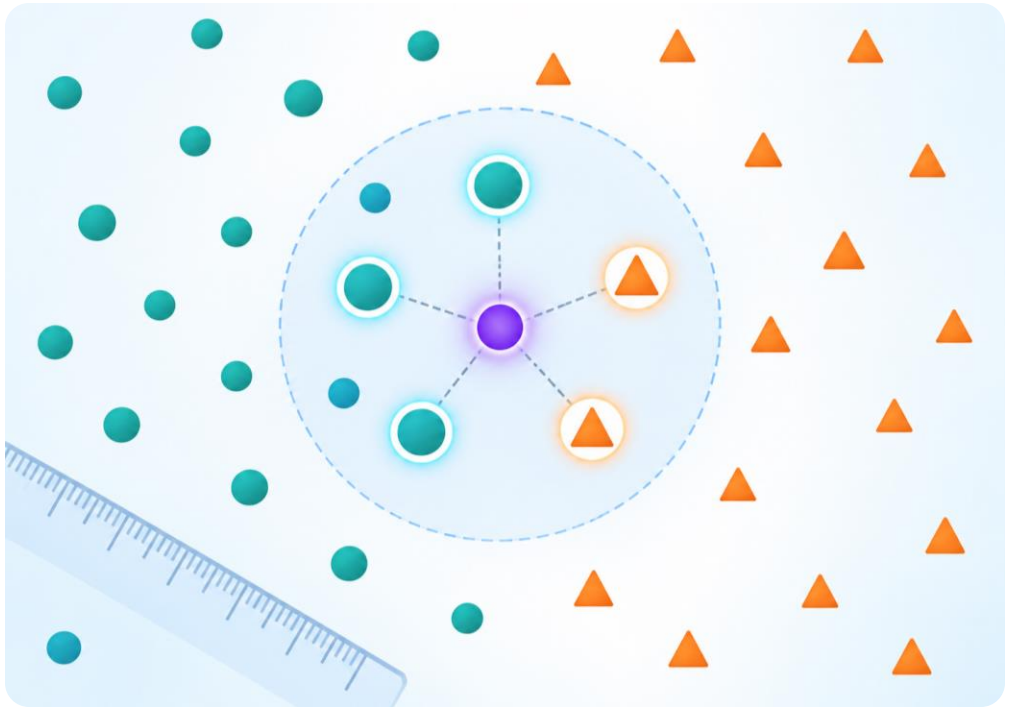
Pertemuan 6

Klasifikasi melalui kedekatan data dan probabilitas bukti



Program Studi Teknik Informatika FTIK

Dua cara membaca satu objek baru



KNN

Siapa tetangga terdekatnya?



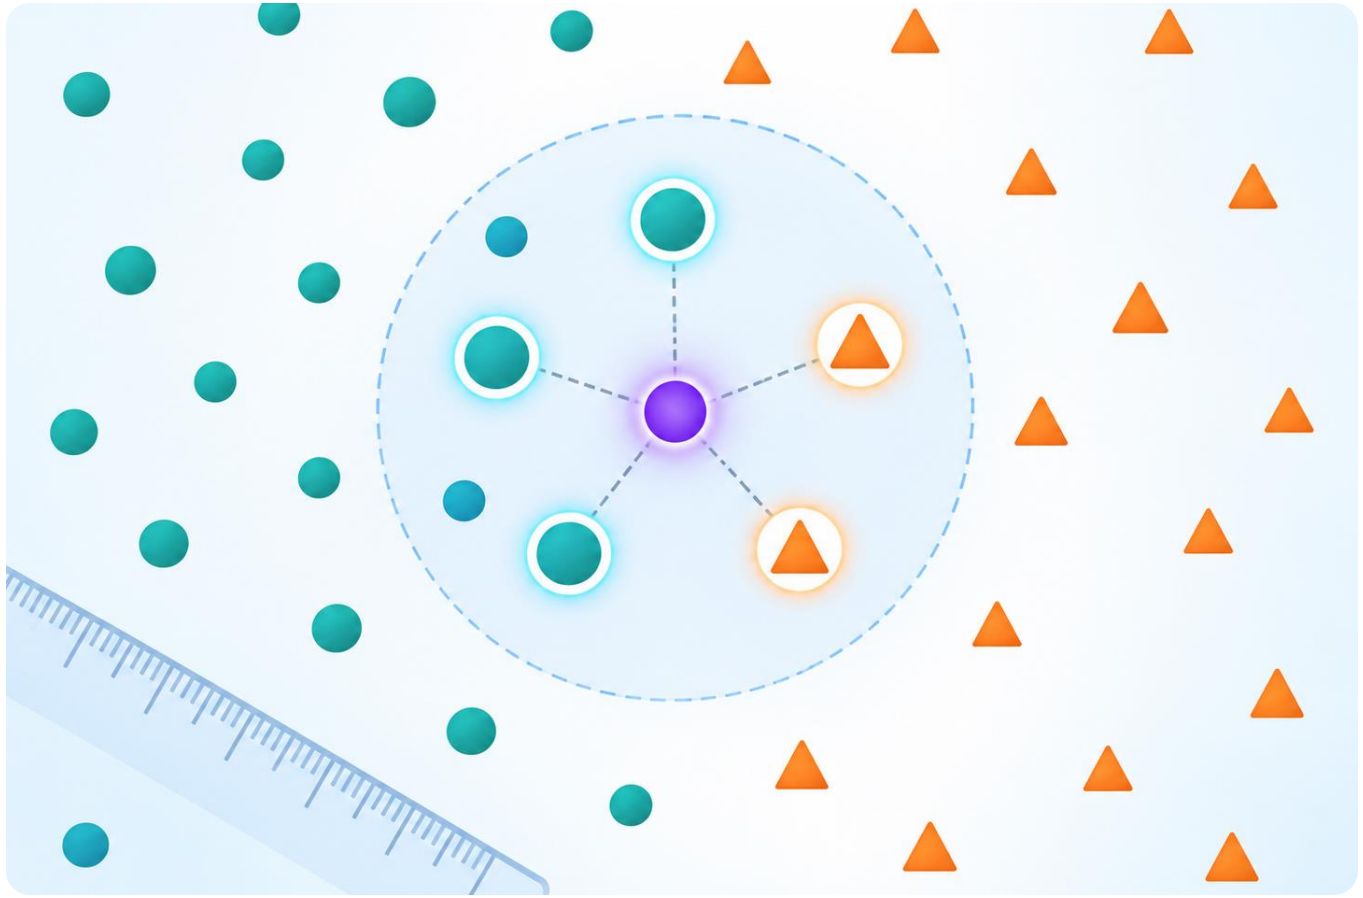
NAIVE BAYES

Bukti mana yang paling mendukung kelas?

Capaian pembelajaran pertemuan 6

01	**Menjelaskan KNN**	tetangga, jarak, nilai k, dan voting
02	**Menghitung jarak**	Euclidean, Manhattan, dan standardisasi
03	**Menjelaskan Naive Bayes**	prior, likelihood, posterior, dan asumsi naif
04	**Membandingkan model**	akurasi, biaya prediksi, serta kecocokan data

KNN memilih kelas dari tetangga terdekat



DATA LATIH

Seluruh contoh beserta labelnya disimpan.

DATA BARU

Jarak ke setiap contoh dihitung saat prediksi.

KEPUTUSAN

Mayoritas dari k tetangga menentukan kelas.

Alur prediksi KNN



Klasifikasi memakai voting. Regresi memakai rata-rata target tetangga.

Biaya prediksi dasar: O(n × d) untuk satu data baru

Metrik jarak memberi definisi yang berbeda untuk dekat

EUCLIDEAN

$d(a,b) = \sqrt{\Sigma(a_i - b_i)^2}$

Jarak garis lurus.
Cocok untuk ruang kontinu dengan skala sebanding.

MANHATTAN

$d(a,b) = \Sigma|a_i - b_i|$

Jarak sepanjang sumbu.
Lebih tahan terhadap selisih ekstrem per fitur.

MINKOWSKI

$d(a,b) = (\Sigma|a_i - b_i|^p)^{1/p}$

p = 1 menghasilkan Manhattan.
p = 2 menghasilkan Euclidean.

Metrik yang berbeda dapat menghasilkan tetangga dan prediksi yang berbeda.

Contoh Euclidean menghasilkan jarak 5

A = (2, 3) **B = (5, 7)**

$$d(A,B) = \sqrt{[(5 - 2)^2 + (7 - 3)^2]}$$

Selisih

(3, 4)

Kuadrat

9 + 16

Akar

√25 = 5

Makna: garis lurus dari A ke B memiliki panjang 5 satuan.

Contoh Manhattan menghasilkan jarak 7

A = (2, 3) **B = (5, 7)**

$$d(A,B) = |5 - 2| + |7 - 3|$$

Sumbu x

$|3| = 3$

Sumbu y

$|4| = 4$

Jumlah

$3 + 4 = 7$

Rute mengikuti sumbu, sehingga jaraknya lebih panjang daripada garis lurus.

Skala besar dapat menguasai perhitungan jarak

FITUR	A	B	SELISIH
Usia	20 tahun	40 tahun	20
Pendapatan	Rp4 juta	Rp10 juta	6.000.000

TANPA SCALING

Pendapatan mendominasi jarak. Kemiripan usia hampir tidak berpengaruh.

DENGAN SCALING

Kedua fitur dibandingkan dalam satuan yang sebanding.

Standardisasi mengubah fitur menjadi satuan simpangan baku

$$z = (x - \mu) / \sigma$$

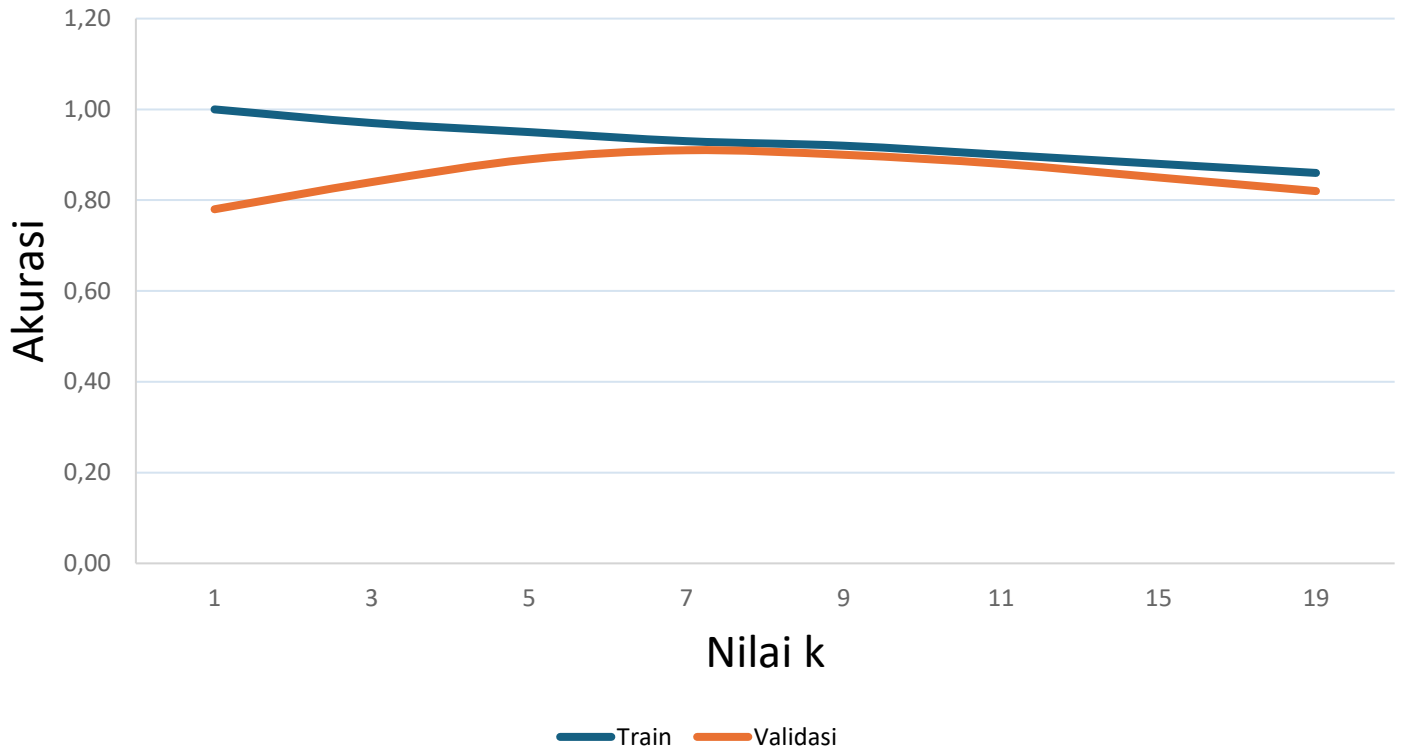
Nilai x	80
Rata-rata μ	50
Simpangan baku σ	10

$$z = (80 - 50) / 10 = 3$$

Nilai 80 berada 3 simpangan baku di atas rata-rata.

Scaler di-fit hanya pada data train untuk mencegah kebocoran data.

Nilai k mengatur kepekaan terhadap pola lokal



k KECIL

Batas sangat rinci. Noise mudah memengaruhi prediksi.

k MENENGAH

Pola lokal tetap terbaca dan prediksi lebih stabil.

Pilih k dengan cross-validation pada data train.

Weighted KNN memberi suara lebih besar kepada tetangga dekat

$$w_i = 1 / d_i$$

Tetangga	Kelas	Jarak	Bobot
1	**A**	1	1,00
2	**B**	2	0,50
3	**A**	4	0,25

SKOR A 1,00 + 0,25 = 1,25

SKOR B 0,50

KNN sederhana dan fleksibel, tetapi prediksinya mahal

KELEBIHAN

1 Mudah dipahami dan diterapkan

2 Menangkap batas nonlinier

3 Mendukung klasifikasi dan regresi

4 Tidak memerlukan asumsi distribusi

KETERBATASAN

1 Prediksi lambat pada data besar

2 Sangat sensitif terhadap skala

3 Fitur tidak relevan merusak jarak

4 Dimensi tinggi melemahkan kedekatan

KNN cocok ketika data tidak terlalu besar dan konsep kemiripan bermakna.

Naive Bayes menggabungkan bukti dengan probabilitas



PRIOR

Seberapa umum kelas sebelum melihat email?

LIKELIHOOD

Seberapa mungkin kata muncul pada kelas itu?

POSTERIOR

Kelas mana paling didukung oleh bukti?

Teorema Bayes memperbarui keyakinan setelah melihat fitur

$$P(C \mid X) = P(X \mid C) \times P(C) / P(X)$$

P(C) PRIOR

keyakinan awal kelas

P(X|C) LIKELIHOOD

peluang fitur jika kelas benar

P(C|X) POSTERIOR

keyakinan setelah melihat fitur

Untuk memilih kelas, penyebut P(X) sama bagi semua kelas dan dapat diabaikan.

Asumsi naif memecah bukti menjadi perkalian sederhana

$$P(X_1, X_2, \ldots, X_n \mid C) = \prod_i P(X_i \mid C)$$

Contoh email

gratis	diskon
rapat	lampiran

MAKNA ASUMSI

Model memperlakukan bukti setiap fitur sebagai kontribusi terpisah setelah kelas diketahui.

Asumsi ini sering tidak sepenuhnya benar, tetapi perhitungannya cepat dan efektif untuk teks.

Fitur yang sangat berkorelasi dapat dihitung seolah memberi bukti ganda.

Tiga varian Naive Bayes mengikuti bentuk fitur

GAUSSIAN	**Nilai kontinu**	Asumsi distribusi normal	**sensor, ukuran fisik**
MULTINOMIAL	**Hitungan atau frekuensi**	Jumlah kemunculan	**bag-of-words**
BERNOULLI	**Nilai biner 0 atau 1**	Ada atau tidak ada	**kata muncul?**

Pilih varian dari representasi fitur, bukan dari nama kasusnya.

Laplace smoothing mencegah peluang nol

$$P(kata_i \mid C) = (count_i, C + \alpha) / (totalC + \alpha V)$$

TANPA SMOOTHING

Jika kata “gratis” tidak pernah muncul pada kelas bukan spam:

P(gratis | bukan spam) = 0/2 = 0

Seluruh hasil perkalian menjadi 0.

DENGAN α = 1

Dua kemungkinan nilai: ya atau tidak.

P(gratis | bukan spam)
= (0 + 1) / (2 + 1 × 2)
= 1/4 = 0,25

Smoothing tidak membuat fitur pasti; smoothing memberi peluang kecil yang masuk akal.

Data latih spam menyediakan prior dan likelihood

Email	gratis	diskon	Label
1	Ya	Ya	Spam
2	Ya	Tidak	Spam
3	Tidak	Tidak	Bukan Spam
4	Tidak	Ya	Bukan Spam
5	Ya	Ya	Spam

PRIOR SPAM 3/5 = 0,60

PRIOR BUKAN SPAM 2/5 = 0,40

Likelihood mengukur kemunculan setiap kata pada tiap kelas

Likelihood	Spam	Bukan Spam
P(gratis = Ya | kelas)	3/3 = 1,00	(0+1)/(2+2) = 0,25
P(diskon = Ya | kelas)	2/3 = 0,667	(1+1)/(2+2) = 0,50

Smoothing diterapkan pada kelas bukan spam karena kata “gratis” belum pernah muncul.

Email baru mengandung kata “gratis” dan “diskon”.

Skor posterior memilih kelas Spam

$$\text{Skor}(C) = P(C) \times P(\text{gratis} \mid C) \times P(\text{diskon} \mid C)$$

SPAM

$0{,}60 \times 1{,}00 \times 0{,}667$

$= 0{,}400$

BUKAN SPAM

$0{,}40 \times 0{,}25 \times 0{,}50$

$= 0{,}050$

0,400 lebih besar daripada 0,050
Prediksi: SPAM

Log probabilitas menjaga perhitungan tetap stabil

$$\log \text{Skor}(C) = \log P(C) + \Sigma_i \log P(X_i \mid C)$$

Perkalian langsung

$0{,}01 \times 0{,}02 \times 0{,}03 \quad = 0{,}000006$

Ruang log

$\ln 0{,}01 + \ln 0{,}02 + \ln 0{,}03 \quad \approx -12{,}02$

Penjumlahan log menghindari underflow saat dokumen memiliki ribuan fitur.

KNN dan Naive Bayes cocok untuk situasi yang berbeda

Aspek	KNN	Naive Bayes
Dasar keputusan	tetangga terdekat	probabilitas fitur
Fase training	hampir tidak ada	menghitung statistik
Biaya prediksi	tinggi pada data besar	sangat rendah
Scaling	sangat penting	biasanya tidak wajib
Kekuatan utama	pola lokal nonlinier	teks berdimensi tinggi

Bandingkan keduanya dengan evaluasi yang sama pada data test yang sama.

Praktikum membandingkan KNN dan Gaussian Naive Bayes

```
from sklearn.pipeline import make_pipeline
from sklearn.preprocessing import StandardScaler
from sklearn.neighbors import KNeighborsClassifier
from sklearn.naive_bayes import GaussianNB
from sklearn.metrics import accuracy_score

knn = make_pipeline(
    StandardScaler(),
    KNeighborsClassifier(n_neighbors=5, weights="distance")
)
nb = GaussianNB()

for name, model in [("KNN", knn), ("NB", nb)]:
    model.fit(X_train, y_train)
    pred = model.predict(X_test)
    print(name, accuracy_score(y_test, pred))
```

DATASET

Gunakan load_wine. Split 80:20 dengan stratify dan random_state = 42.

LAPORAN

Bandingkan akurasi, waktu fit, waktu prediksi, dan alasan hasil berbeda.

Tambahan: uji k = 1 sampai 20 dengan cross-validation.

Kesimpulan

1. KNN memprediksi dari kelas tetangga terdekat.
2. Scaling menentukan apakah jarak antar fitur adil.
3. Nilai k menyeimbangkan pola lokal dan kestabilan.
4. Naive Bayes menggabungkan prior dengan likelihood.
5. Smoothing mencegah peluang nol menghapus bukti lain.

KNN dengan k = 5 memiliki tiga tetangga kelas A dan dua kelas B. Apa prediksinya?
Mengapa scaling perlu dilakukan sebelum menghitung jarak?