MATA KULIAH MACHINE LEARNING

Evaluasi Model Klasifikasi

Pertemuan 7

Confusion Matrix, Precision-Recall, ROC-AUC, dan Stratified K-Fold CV



Program Studi Teknik Informatika FTIK

Akurasi tinggi belum menjamin kasus penting terdeteksi



AKURASI

96%

RECALL KANKER

60 dari 100 kasus terdeteksi

Pertanyaan utama: kesalahan mana yang paling berbahaya?

Capaian pembelajaran pertemuan 7

01	**Membaca confusion matrix**	TP, TN, FP, dan FN
02	**Menghitung metrik**	accuracy, precision, recall, F1, dan F-beta
03	**Menilai threshold**	ROC-AUC dan Precision-Recall Curve
04	**Mengevaluasi secara jujur**	Stratified K-Fold CV dan test final

Pembagian peran data menjaga evaluasi tetap jujur

1

TRAIN

Mempelajari parameter model

2

VALIDATION / CV

Memilih model dan threshold

3

TEST

Mengukur hasil akhir satu kali

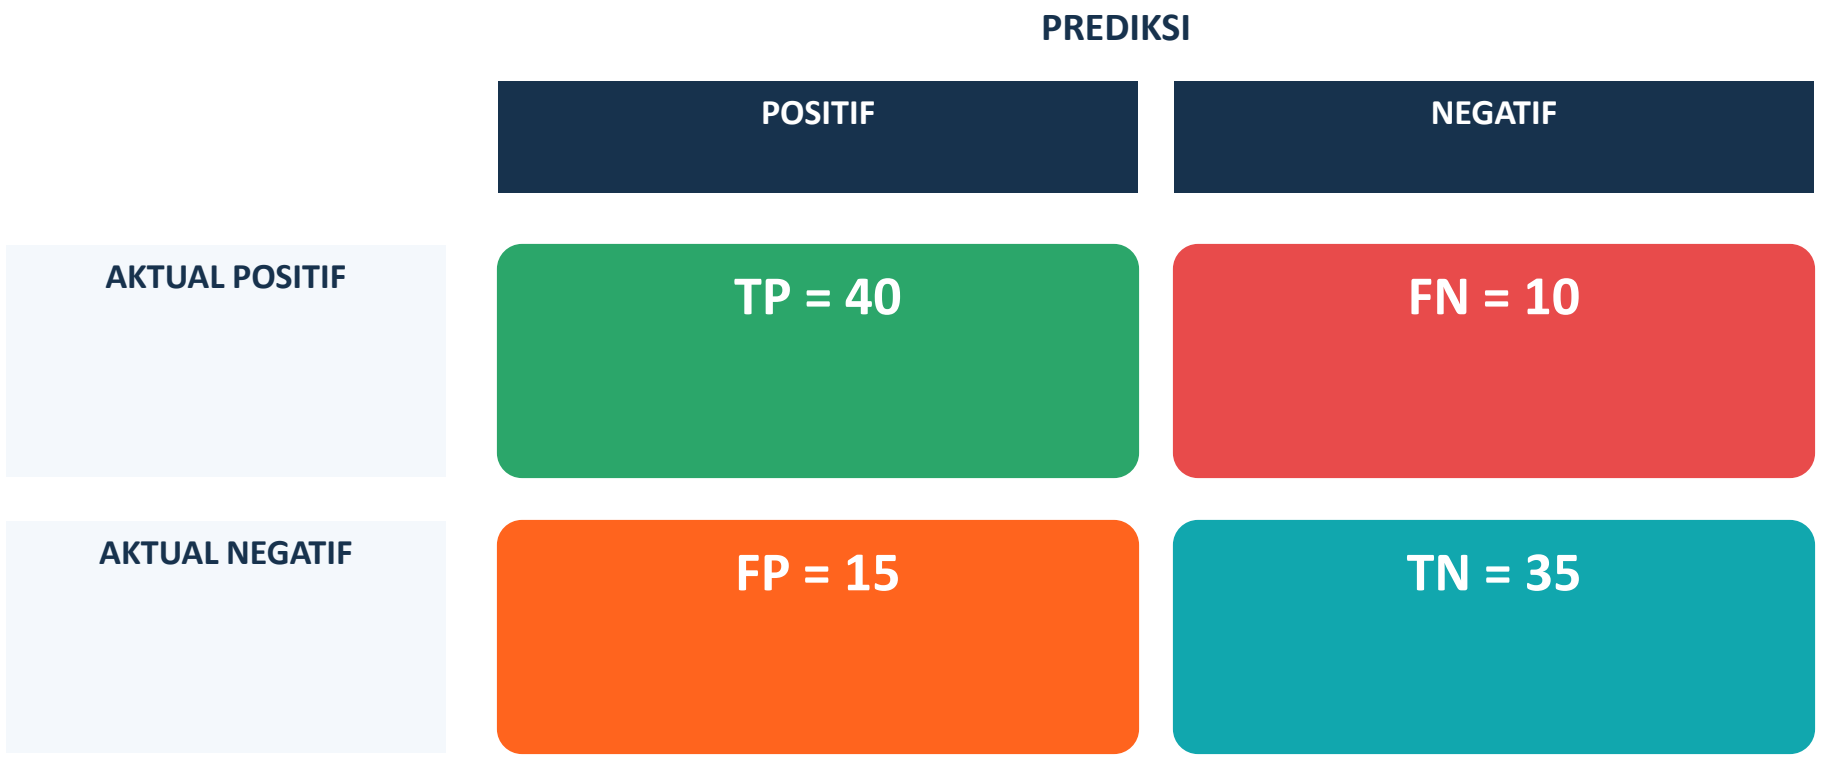
Test tidak dipakai untuk tuning, seleksi fitur, atau memilih threshold.

Confusion matrix memetakan empat hasil prediksi

		PREDIKSI: POSITIF	PREDIKSI: NEGATIF
AKTUAL	POSITIF	**TRUE POSITIVE** Prediksi benar positif	**FALSE NEGATIVE** Positif yang terlewat
	NEGATIF	**FALSE POSITIVE** Alarm palsu	**TRUE NEGATIVE** Prediksi benar negatif

Positif harus ditentukan dari tujuan kasus, bukan dari kelas mayoritas.

Contoh confusion matrix: 100 data



Benar: 75 data Salah: 25 data

Accuracy menghitung seluruh prediksi yang benar

$$\text{Accuracy} = (TP + TN) / (TP + TN + FP + FN)$$

$$\text{Accuracy} = (40 + 35) / (40 + 35 + 15 + 10)$$

Prediksi benar

40 + 35 = 75

Seluruh data

100

Hasil

75 / 100 = 0,75

Accuracy = 75%

Precision menilai ketepatan prediksi positif

Precision = TP / (TP + FP)

Precision = 40 / (40 + 15) = 40 / 55

PERTANYAAN

Dari semua yang diprediksi positif, berapa yang benar?

HASIL

Precision = 0,727 atau 72,7%

Recall menilai berapa kasus positif yang ditemukan

Recall = TP / (TP + FN)

Recall = 40 / (40 + 10) = 40 / 50

PERTANYAAN

Dari semua kasus positif aktual, berapa yang terdeteksi?

HASIL

Recall = 0,800 atau 80,0%

F1-Score menyeimbangkan precision dan recall

F1 = 2 × (Precision × Recall) / (Precision + Recall)

Masukkan nilai	2 × (0,727 × 0,800) / (0,727 + 0,800)
Hitung pembilang	2 × 0,582 = 1,164
Bagi	**1,164 / 1,527 = 0,762**

F1-Score = 0,762

F-beta menyesuaikan bobot recall dan precision

$$F\beta = (1 + \beta^2) \times (\text{Precision} \times \text{Recall}) / (\beta^2 \times \text{Precision} + \text{Recall})$$

β = 1

Bobot seimbang.

F1 = 0,762

β > 1

Recall lebih penting.

Contoh: F2 untuk skrining

β < 1

Precision lebih penting.

Contoh: F0,5 untuk alarm mahal

Nilai beta harus mengikuti biaya kesalahan pada kasus nyata.

Kelas tidak seimbang dapat membuat accuracy menipu

DATA: 1.000 orang

NEGATIF

990

POSITIF

10

MODEL SELALU MEMPREDIKSI NEGATIF

ACCURACY

990/1.000 = 99%

RECALL POSITIF

0/10 = 0%

Threshold mengubah skor probabilitas menjadi kelas



THRESHOLD TURUN

Lebih banyak prediksi positif. Recall cenderung naik, FP juga bertambah.

THRESHOLD NAIK

Lebih sedikit prediksi positif. Precision dapat naik, FN juga bertambah.

Threshold dipilih dari validation atau CV, bukan dari test.

Perubahan threshold menghasilkan trade-off

Threshold	Prediksi positif	Recall	False positive
Lebih rendah	lebih banyak	cenderung naik	cenderung naik
Lebih tinggi	lebih sedikit	cenderung turun	cenderung turun

FOKUS RECALL

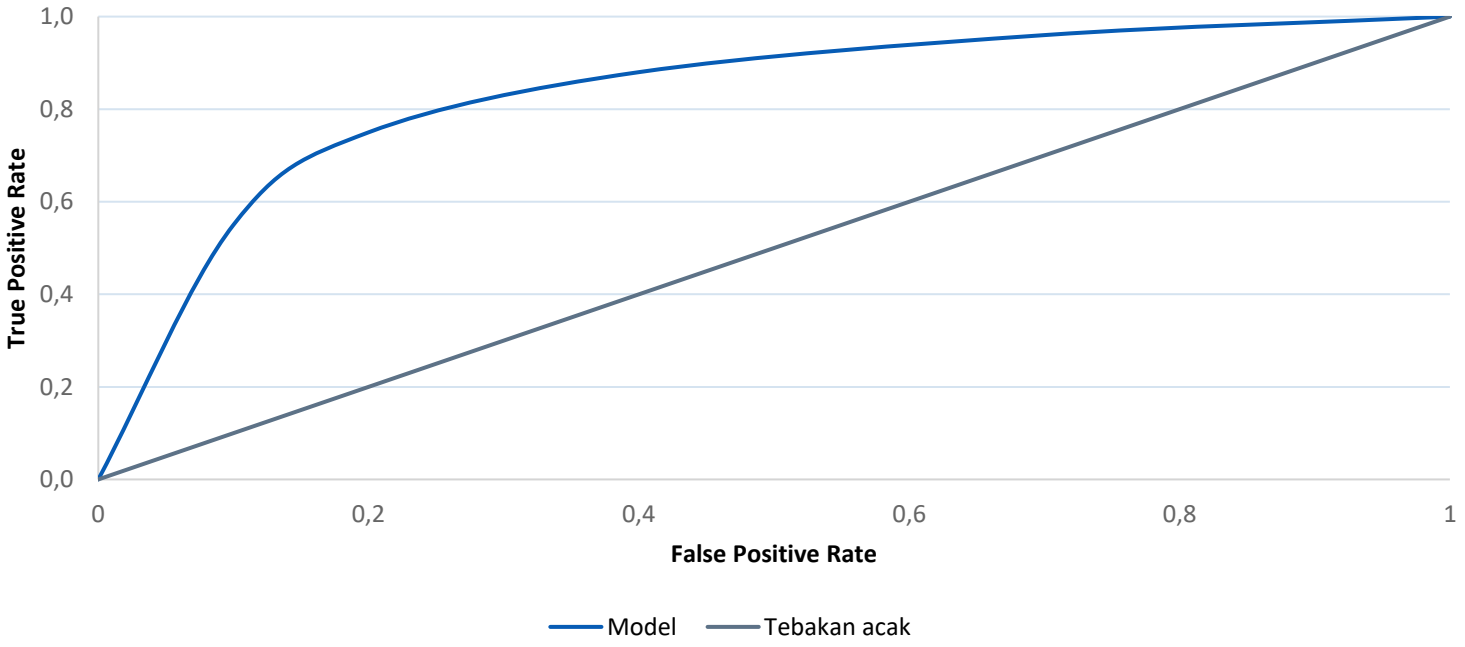
Turunkan threshold bila FN sangat mahal.

FOKUS PRECISION

Naikkan threshold bila FP sangat mahal.

ROC Curve menilai pemisahan pada banyak threshold

$$TPR = TP/(TP+FN) \qquad FPR = FP/(FP+TN)$$

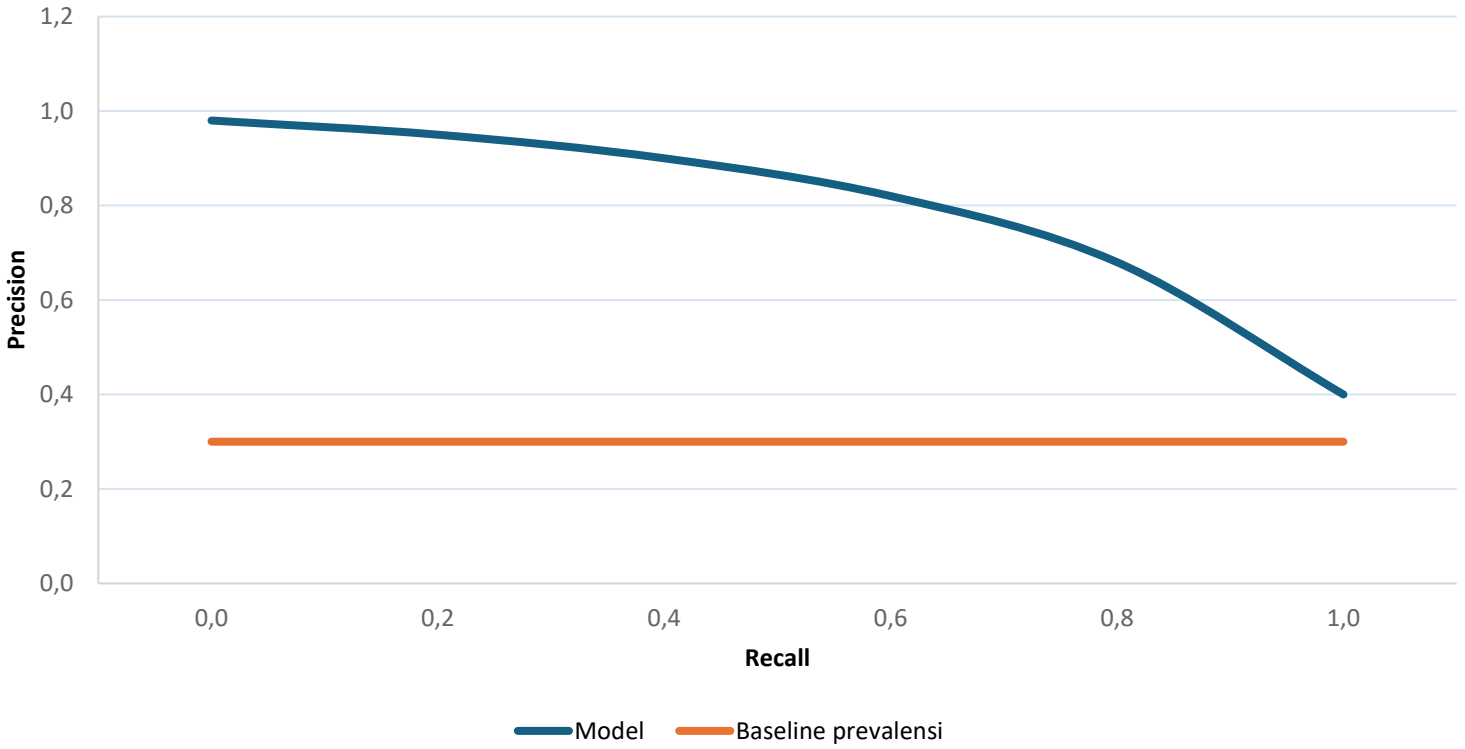


AUC ≈ 0,83

Model cukup baik mengurutkan positif di atas negatif.

AUC 0,5 setara urutan acak. AUC 1,0 berarti pemisahan sempurna.

Precision-Recall Curve fokus pada kelas positif



LEBIH INFORMATIF

PR Curve menyoroti kualitas prediksi kelas minoritas positif.

BASELINE

Precision dasar mengikuti prevalensi kelas positif.

ROC-AUC dan PR-AUC menjawab fokus berbeda

Aspek	ROC-AUC	PR-AUC
Sumbu	TPR vs FPR	Precision vs Recall
Fokus	kemampuan pemisahan	kelas positif
Cocok untuk	kelas relatif seimbang	positif sangat jarang
Keterbatasan	dapat tampak optimis	lebih sulit dibandingkan lintas prevalensi

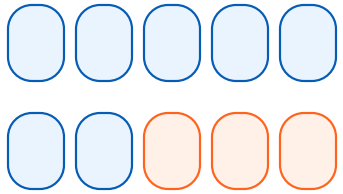
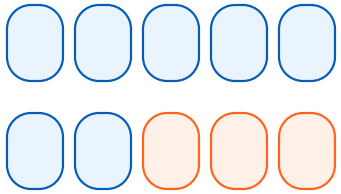
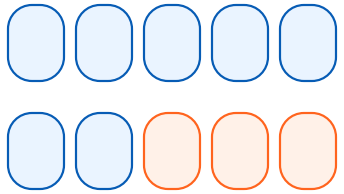
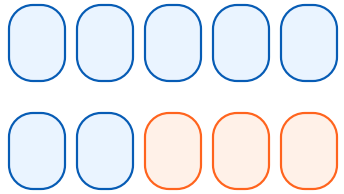
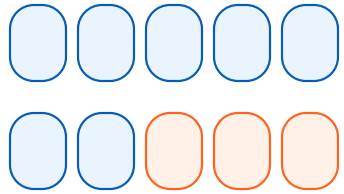
Laporkan kurva yang selaras dengan distribusi kelas dan tujuan keputusan.

Averaging merangkum metrik multiclass

MACRO	**Rata-rata tiap kelas tanpa bobot**	Semua kelas dianggap sama penting
MICRO	**Gabungkan TP, FP, dan FN**	Menilai keputusan keseluruhan
WEIGHTED	**Bobot mengikuti jumlah data per kelas**	Kelas besar lebih berpengaruh

Contoh F1 kelas A = 0,90; B = 0,60; C = 0,30
Macro F1 = (0,90 + 0,60 + 0,30) / 3 = 0,60

Stratified K-Fold menjaga proporsi kelas pada setiap fold

FOLD 1	FOLD 2	FOLD 3	FOLD 4	FOLD 5
				
7 negatif 3 positif	7 negatif 3 positif	7 negatif 3 positif	7 negatif 3 positif	7 negatif 3 positif

Putaran 1

Fold 1 menjadi validation

Putaran 2

Fold 2 menjadi validation

Sampai 5

Setiap fold dipakai sekali

Rata-rata dan standar deviasi menunjukkan level dan stabilitas

1	2	3	4	5
0,78	0,82	0,80	0,84	0,76

$$\text{Mean} = (0{,}78 + 0{,}82 + 0{,}80 + 0{,}84 + 0{,}76) / 5 = 0{,}800$$

$$SD = \sqrt{[\Sigma(\text{skor}_i - \text{mean})^2 / 5]} = \sqrt{0{,}0008} = 0{,}028$$

Laporan: F1 = 0,800 ± 0,028

Kebocoran data membuat skor tampak lebih baik dari kenyataan

TIDAK JUJUR

1 Scaling sebelum split

2 Seleksi fitur memakai seluruh data

3 Mencoba banyak model pada test

4 Memilih threshold dari test

JUJUR

1 Fit preprocessing pada train

2 Pilih model melalui CV train

3 Kunci pipeline dan threshold

4 Gunakan test satu kali

Pipeline membantu menjaga preprocessing tetap berada di dalam setiap fold CV.

Threshold skrining memprioritaskan recall



SEBELUM

Accuracy 96%
Recall kanker 60%

SETELAH THRESHOLD TURUN

Recall kanker 92%
Precision menurun

Pemeriksaan lanjutan lebih murah daripada melewatkan kanker.

Kode menghitung metrik dan Stratified 5-Fold CV

```
from sklearn.metrics import (
    confusion_matrix, precision_score,
    recall_score, f1_score
)
from sklearn.model_selection import (
    StratifiedKFold, cross_val_score
)

y_pred = model.predict(X_test)
print(confusion_matrix(y_test, y_pred))
print("precision", precision_score(y_test, y_pred))
print("recall", recall_score(y_test, y_pred))
print("f1", f1_score(y_test, y_pred))

cv = StratifiedKFold(5, shuffle=True, random_state=42)
scores = cross_val_score(model, X_train, y_train,
                         cv=cv, scoring="f1")
print(scores.mean(), scores.std())
```

CATATAN

CV dijalankan pada train. Test tetap disimpan untuk evaluasi akhir.

OUTPUT

Confusion matrix, precision, recall, F1, mean CV, dan SD CV.

Praktikum menyusun laporan evaluasi lengkap

1. Muat load_breast_cancer
2. Split stratified 70:30
3. Latih Logistic Regression dan Decision Tree
4. Hitung confusion matrix dan metrik
5. **Bandingkan ROC, PR, mean CV, dan SD**

LAPORAN WAJIB

1 Confusion matrix
2 Precision, recall, dan F1
3 ROC-AUC dan PR Curve
4 Mean serta SD 5-fold CV
5 Alasan memilih model

Pertanyaan analisis
Model mana yang paling aman jika false negative lebih mahal?

Kesimpulan

1. Confusion matrix menunjukkan jenis kesalahan model.
2. Precision berfokus pada prediksi positif yang benar.
3. Recall berfokus pada kasus positif yang ditemukan.
4. ROC dan PR membaca perilaku pada banyak threshold.
5. CV memilih model; test mengukur hasil akhir satu kali.

Jika TP = 30, FP = 10, dan FN = 20, hitung precision dan recall.
Metrik mana yang diprioritaskan jika false negative sangat mahal?