Parameter gamma pada kernel RBF mengontrol seberapa jauh pengaruh satu titik data latih gamma besar berarti pengaruh hanya terasa pada titik yang sangat dekat (batas keputusan sangat berliku, berisiko overfitting), sementara gamma kecil membuat pengaruh menyebar lebih jauh (batas keputusan lebih halus, berisiko underfitting).

8.5. Algoritma Pelatihan SVM (Gambaran Umum)

- Pilih kernel (linear/polynomial/RBF) berdasarkan pemahaman awal terhadap struktur data.
- Tentukan kandidat nilai hyperparameter C (dan gamma jika menggunakan kernel non-linear).
- Selesaikan masalah optimasi kuadratik untuk menemukan w, b yang memaksimalkan margin dengan penalti C terhadap kesalahan.
- Identifikasi support vectors titik data yang berada tepat pada margin atau melanggarnya.
- Gunakan GridSearchCV dengan cross-validation untuk memilih kombinasi C dan gamma terbaik.
- Evaluasi model akhir pada test set menggunakan metrik yang sesuai (Bab 7).

8.6. Kelebihan dan Kekurangan SVM

Kelebihan	Kekurangan
Efektif pada data berdimensi tinggi, bahkan ketika jumlah fitur melebihi jumlah sampel	Waktu pelatihan lambat pada dataset sangat besar (kompleksitas kuadratik hingga kubik)
Kernel trick memungkinkan penanganan hubungan non-linear yang kompleks	Kinerja sangat bergantung pada pemilihan kernel dan tuning hyperparameter
Hanya bergantung pada support vectors sehingga robust terhadap data baru yang jauh dari margin	Kurang interpretable dibandingkan Decision Tree, terutama pada kernel non-linear
—	Tidak menghasilkan probabilitas secara native (memerlukan kalibrasi seperti Platt scaling)

8.7. Kompleksitas

Pelatihan SVM standar berkompleksitas $O(n^2)$ hingga $O(n^3)$ terhadap jumlah sampel karena menyelesaikan masalah optimasi kuadratik atas seluruh pasangan data. Untuk data berskala jutaan, gunakan varian teroptimasi seperti LinearSVC yang mendekati linear.

8.8. Studi Kasus

Tabel 1. Klasifikasi Subtipe Kanker dari Data Ekspresi Gen

Aspek	Uraian
Masalah	Data ekspresi gen memiliki ribuan fitur namun hanya ratusan sampel pasien kondisi high-dimensional, low-sample-size.
Solusi & Proses	SVM kernel linear dipilih karena unggul pada data berdimensi tinggi dengan sampel terbatas, kondisi yang justru menyulitkan Decision Tree maupun KNN. Nilai C optimal dicari dengan GridSearchCV 5-fold.
Hasil & Interpretasi	SVM linear yang telah di-tuning jauh mengungguli baseline KNN, menegaskan kesesuaian SVM untuk data genomik dan bioinformatika.

23mm f/1.8 1/50s ISO796
NOTE 40

8.9. Contoh Perhitungan

Diberikan hyperplane sederhana pada ruang 2D dengan w = (2, 1) dan b = -5. Hitung lebar margin dan tentukan sisi kelas untuk titik baru (4, 2).

```
||w|| = sqrt(2^2 + 1^2) = sqrt(5) = 2.236
Lebar_margin = 2 / ||w|| = 2 / 2.236 = 0.894

Fungsi keputusan untuk titik (4,2):
f(x) = w.x + b = (2*4 + 1*2) - 5 = (8+2) - 5 = 5
Karena f(x) = 5 > 0,
    maka titik (4,2) diklasifikasikan pada sisi POSITIF hyperpla
    ne.
```

8.10. Implementasi Python

Praktikum 8.1 Persiapan Library

```
1. import numpy as np
2. import matplotlib.pyplot as plt
3. from sklearn.datasets import load_breast_cancer
4. from sklearn.model_selection import train_test_split,
5.     GridSearchCV
6. from sklearn.preprocessing import StandardScaler
7. from sklearn.svm import SVC
8. from sklearn.pipeline import Pipeline
9. from sklearn.metrics import classification_report,
10.    accuracy_score
```

Praktikum 8.2 Import Dataset

```
1. data = load_breast_cancer(as_frame=True)
2. X, y = data.data, data.target
3. X_train,X_test,y_train,y_test = train_test_split(X,y,
4.     test_size=0.2,random_state=42,stratify=y)
```

Praktikum 8.3 Preprocessing

```
1. # SVM sangat sensitif terhadap skala fitur,
2.     scaling WAJIB dilakukan
3. pipeline = Pipeline([ ("scaler",StandardScaler()),("svm",
4.     SVC()) ])
```

Praktikum 8.4 Training Model dengan GridSearchCV

```
1. param_grid = { "svm__C": [0.1,1,10,100],
2.     "svm__gamma": [0.001,0.01,0.1,1],"svm__kernel": ["rbf",
3.     "linear"] }
4. grid_search = GridSearchCV(pipeline,param_grid,cv=5,
5.     scoring="f1",n_jobs=-1)
6. grid_search.fit(X_train, y_train)
7.
8. print("Parameter terbaik:", grid_search.best_params_)
9. print("F1-Score terbaik (CV):",
10.    round(grid_search.best_score_,3))
```

Praktikum 8.5 Evaluasi

```
1. best_model = grid_search.best_estimator_
2. y_pred = best_model.predict(X_test)
3. print("Akurasi Test:",round(accuracy_score(y_test,y_pred),
4.     3))
```


NOTE 40 23mm f/1.8 1/50s ISO773

```
print(classification_report(y_test, y_pred))
```

Praktikum 8.6 Visualisasi

```
import pandas as pd
hasil = pd.DataFrame(grid_search.cv_results_)
pivot = hasil.pivot_table(values="mean_test_score",
    index="param_svm__C",columns="param_svm__gamma")
plt.imshow(pivot, cmap="viridis", aspect="auto")
plt.xticks(range(len(pivot.columns)), pivot.columns)
plt.yticks(range(len(pivot.index)), pivot.index)
plt.xlabel("gamma"); plt.ylabel("C")
plt.title("Heatmap F1-Score terhadap Kombinasi C dan gamma
    (kernel RBF)")
plt.colorbar(label="F1-Score")
plt.show()
```

8.10.1. Interpretasi

Heatmap hasil GridSearchCV membantu memvisualisasikan wilayah kombinasi C dan gamma yang menghasilkan performa terbaik. Umumnya, area "puncak" performa berada pada rentang tertentu nilai C dan gamma yang jauh lebih besar atau lebih kecil dari area tersebut menghasilkan performa yang menurun karena overfitting atau underfitting.

8.11. Latihan Praktikum

- Praktikum 1: Perbandingan Kernel

Tujuan: Membandingkan performa kernel linear, polynomial, dan RBF pada dataset yang sama.

Praktikum 8.7

```
for kernel in ["linear", "poly", "rbf"]:
    model = Pipeline([("scaler",StandardScaler()),("svm",
        SVC(kernel=kernel))])
    model.fit(X_train, y_train)
    acc = accuracy_score(y_test, model.predict(X_test))
    print(f"Kernel {kernel}: akurasi = {acc:.3f}")
```

- Praktikum 2: Visualisasi Decision Boundary 2 Fitur

Tujuan: Memvisualisasikan pengaruh kernel dan parameter C/gamma pada decision boundary.

Instruksi: Pilih 2 fitur dari dataset load_breast_cancer, latih SVM dengan beberapa kombinasi kernel/C/gamma, dan visualisasikan decision boundary masing-masing seperti pada Gambar 9.3.

NOTE 40

23mm f/1.8 1/50s ISO717